



arxiv 2026.6.9

AgenticNav: Zero-Shot Vision-and-Language Navigation as a Tool-Calling Harness

Yijian Li¹ Changze Li¹ Hantian Shi¹ Jiaying Luo¹

Jiyuan Cai² Ming Yang¹ Tong Qin^{1*}

¹Shanghai Jiao Tong University

²Huawei Technologies Ltd.

<https://github.com/AgenticNav/mas-llm-robotics>

VLN-CE

Agent在连续3d空间中，接收RGBD输入和自然语言命令，不断输出前进，左右转等命令，最终完成命令

连续环境中的视觉语言导航


“走出卧室，沿着铺地毯的走廊直走，穿过开放式客厅，在挂有白色圆盘时钟的那面墙前右转，进入厨房后停在灰色岛台旁边的冰箱前”

1. **VLM与机器人是分离的。** VLM可以根据语言和图像推理，但机器人最终必须与空间复杂的环境交互。现有方法中，VLM无法直接参与与环境的交互

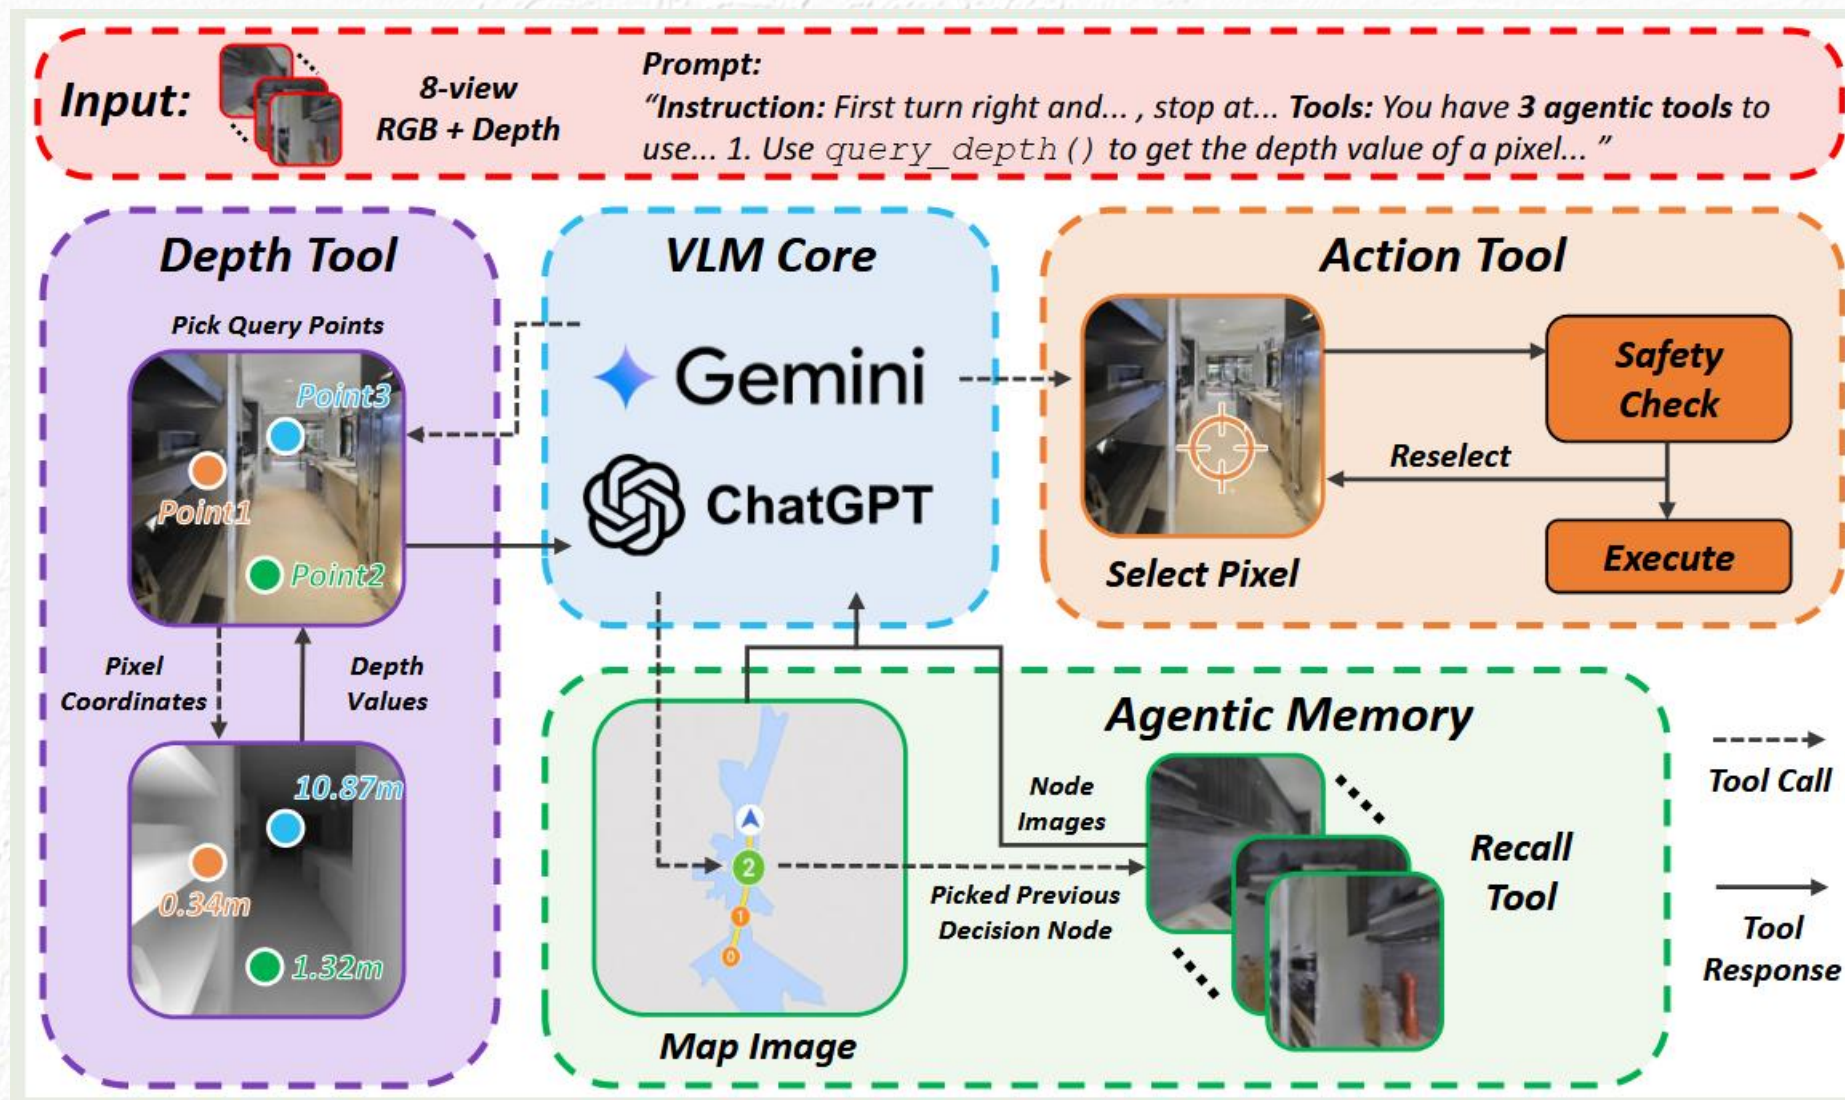
3. **VLM无法获取和利用深度图中的空间信息。** 现有方法中深度信息只用于生成候选点供VLM选择，VLM不能直接从深度图中获取空间信息

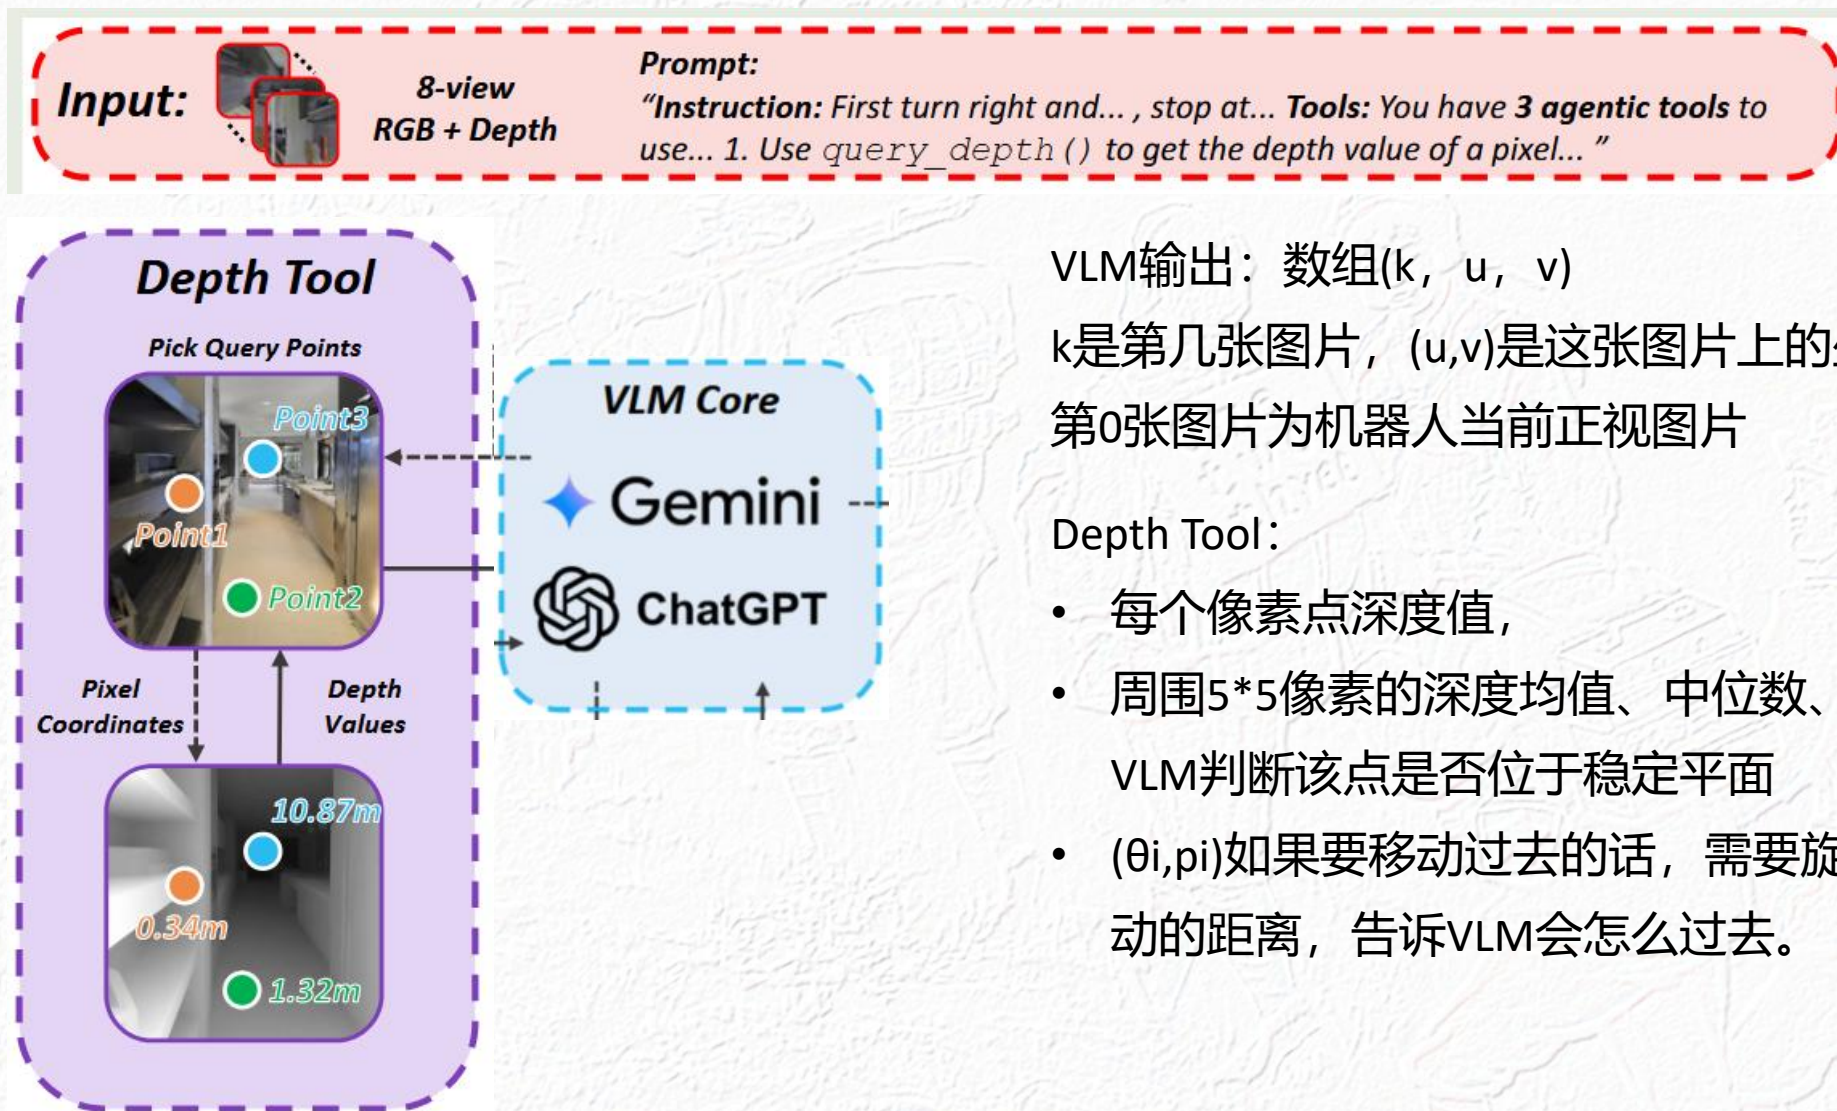
2. **VLM可选动作空间受限。** 现有方法要么通过预训练的航点规划器，要么直接通过几何方式获取前沿点用于VLM选择，所有这些方法都限制了VLM能选择的动作空间

4. **记忆上下文太长检索困难。** 许多方法通过向提示添加更多的文本或视觉上下文来保持记忆。这有助于进度跟踪，但大多数过去的上下文与当前决策无关，并且可能会随着上下文的增长而分散模型的注意力



- (1) 允许VLM通过动作工具调用直接选择像素目标，消除了对训练的航路点预测器的依赖，同时展示了更好的性能。（小模型做不到）
- (2) 允许VLM通过深度工具调用直接获取指定像素的深度值，比航点预测或直接的深度图像输入更有效。
- (3) 允许VLM通过记忆工具调用直接获取曾经走过的某一步的360度观测图，通过俯视图来帮助VLM获取曾经到达的地方的上下文






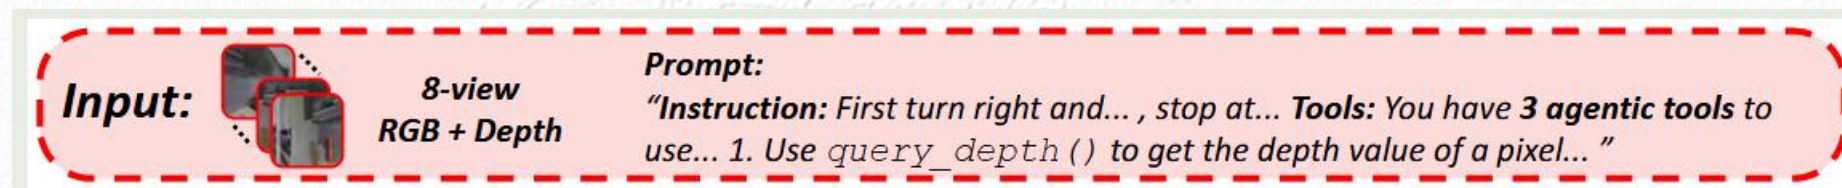
VLM输出: 数组(k, u, v)

k 是第几张图片, (u, v)是这张图片上的坐标

第0张图片为机器人当前正视图图片

Depth Tool:

- 每个像素点深度值,
- 周围 5×5 像素的深度均值、中位数、最小值, 辅助VLM判断该点是否位于稳定平面
- (θ_i, p_i)如果要移动过去的话, 需要旋转的角度和移动的距离, 告诉VLM会怎么过去。



只维护当前任务的记忆

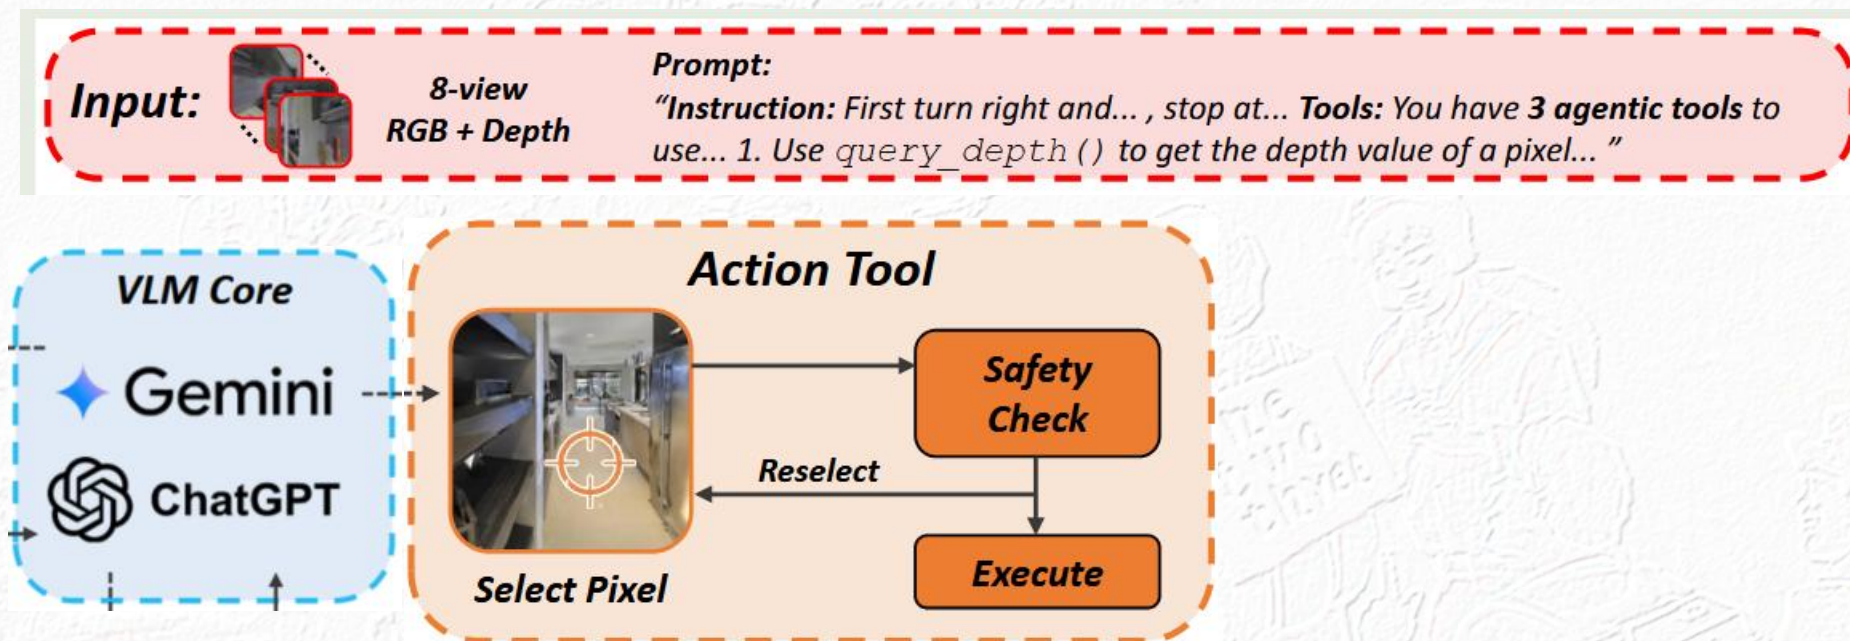
VLM输入: Bt(俯视图, 提供全局空间认知)

VLM输出: (p,k) p是俯视图上某一历史位置,
k是该历史位置下的那一张图

之后会将这个召回图放到Prompt中

上下文按需膨胀

上下文长度仅随任务相关的实际召回
次数增长, 而不是随着步数线性增长,
且主动权交给VLM



VLM输出：像素点坐标(k, u, v)
 k 是第几张图片，(u, v)是这张图片上的坐标

Action Tool:

1. 先将该点转换到相机坐标系下的三维坐标点
2. 计算偏航角和可执行的前进距离（直线距离）
3. 几何安全检查：把所有深度点反投影到三维空间，从机器人到目标点生成一个矩形走廊，对走廊和所有深度点进行碰撞检测

Depth Tool provides precise spatial evidence for correct turn timing.



Instruction: Find and go to the intern desk according to the sign.

FRONT_RGB



FRONT_DEPTH (HIDDEN)



query_depth(view=front, selected_pixels)		
● sign / wall (u=0.57, v=0.16)	3.89m	depth(sign)
● wall plane (u=0.50, v=0.55)	3.87m	is larger than
● floor target (u=0.50, v=0.72)	1.64m	depth(floor)

VLM Reasoning:
sign is still **farther** than nearby floor
→ haven't reached the turning yet
→ continue **straight**, not left

move_to(view=front, u=0.50, v=0.72)




AgenticNav Full



w/o Depth Tool

Recall Tool converts a one-time sign reading into a persistent route constraint.

Instruction: Move along the direction to Building 17, and stop at the entrance on the left.




Recalled Initial View



Current View



Map Image



recall(point_id=1)

VLM Reasoning:
recalled initial sign confirms that Building 17 lies along the current long-horizon direction. I should continue moving forward.





stop()

Action Tool bypasses waypoint constraints by enabling the VLM to directly select a goal-aligned action.

Instruction: Go to the farthest computer desk.




AgenticNav (Action Tool)

Smartway (Waypoint Predictor)

Waypoint predictor
→ Prediction misses goal direction
→ Forced wrong turn

Bird's Eye View



Desired Direction

Smartway VLM: "...The farthest computer desks are visible ahead, but no candidate waypoint directly goes that way."

Action Tool
→ Goal direction directly selectable
→ VLM chooses correctly




Depth Tool provides precise spatial evidence for correct turn timing.



Instruction: Find and go to the intern desk according to the sign.

FRONT_RGB



FRONT_DEPTH (HIDDEN)




query_depth(view=front, selected_pixels)

Object	(u, v)	Depth
sign / wall	(u=0.57, v=0.16)	3.89m
wall plane	(u=0.50, v=0.55)	3.87m
floor target	(u=0.50, v=0.72)	1.64m

depth(sign) is larger than depth(floor)

VLM Reasoning:
sign is still **farther** than nearby floor
→ haven't reached the turning yet
→ continue **straight**, not left

move_to(view=front, u=0.50, v=0.72)



AgenticNav Full

w/o Depth Tool

Recall Tool converts a one-time sign reading into a persistent route constraint.

Instruction: Move along the direction to Building 17, and stop at the entrance on the left.



Recalled Initial View



Current View



Map Image



VLM Reasoning:
recalled initial sign confirms that Building 17 lies along the current long-horizon direction. I



Method	Laboratory		Office		Yard		Overall	
	SR↑	NE↓	SR↑	NE↓	SR↑	NE↓	SR↑	NE↓
SmartWay-GPT-5.5 (12 view) [4]	37.5	2.72	20.0	2.55	14.3	6.75	23.3	3.57
AgenticNav-GPT-5.5 (1 view) (ours)	50.0	2.54	33.3	2.21	14.3	6.08	33.3	3.20
AgenticNav-GPT-5.5 (4 view) (ours)	62.5	2.07	40.0	1.97	42.9	4.86	46.7	2.67

Table 2: Real-world comparison.



R2R-CE val unseen

Method	Depth Input	Trained Modules	Episodic Zero-shot	SR↑	SPL↑	OSR↑	nDTW↑	NE↓
VLN-CE with supervised learning								
CMA [13]	✓	✓	×	37	32.17	45	50.77	6.92
RecBERT [13]	✓	✓	×	48	43.22	57	54.81	5.8
BEVBert [15] ICCV,2023	✓	✓	×	60	53.41	64	61.40	5.13
ETPNav [16] TPAMI,2025	✓	✓	×	58	52.19	63	61.16	5.16
Zero-shot VLN-CE								
Random	—	—	—	2	1.50	12	34.08	8.63
LXMERT [13]	✓	✓	✓	2	1.87	22	18.73	10.48
MapGPT-CE-GPT4o† [26, 4]	×	×	✓	7	5.04	21	-	8.16
DiscussNav-GPT4† [25, 4]	×	✓	✓	11	10.51	15	42.87	7.77
NavGPT-CE-GPT4† [24, 5]	✓	✓	✓	16.30	10.20	26.9	-	8.37
Open-Nav-GPT4 [3]	✓	✓	✓	19	16.10	23	45.79	6.70
Open-Nav-Gemini-2.5-pro [3, 5]	✓	✓	✓	23	19.90	30	49.51	7.28
Open-Nav-Gemini-3-Flash* [3]	✓	✓	✓	32	27.65	42	54.82	6.42
EvoNav-Gemini-2.5-pro [‡] [5]	✓	✓	×	43	<u>37.77</u>	51	<u>62.38</u>	5.04
SmartWay-GPT-5.5* [4]	✓	✓	✓	44	35.04	60	58.64	<u>5.16</u>
AgenticNav-Gemini-2.5-pro (ours)	✓	×	✓	<u>49</u>	33.20	<u>63</u>	48.73	5.91
AgenticNav-GPT-5.5 (ours)	✓	×	✓	55	48.41	65	63.41	5.19

SPL:路径长度加权的成功率

OSR:轨迹中有到目标附近就算成功

nDTW:和GT路径的重合程度

NE:最终位置距离目标的距离

Variant	SR↑	SPL↑	OSR↑	nDTW↑	NE↓
AgenticNav-GPT-5.5 (full)	55	48.41	65	63.41	5.19
w/o Action Tool; Use waypoint predictor instead	50	43.99	59	61.46	5.09
w/o Depth Tool	42	37.82	50	55.57	5.37
w/o Depth Tool; Add depth images as input	53	46.74	60	63.17	5.06
w/o agentic memory	41	33.82	55	48.34	6.28
w/o memory Recall Tool; Only map image	51	44.28	61	59.62	5.18

Table 3: **AgenticNav-GPT-5.5** tool ablation on R2R-CE.

VLM Backbone	SR↑	SPL↑	OSR↑	nDTW↑	NE↓
GPT-5.5	55	48.41	65	63.41	5.19
Gemini-2.5-Pro	49	33.20	63	48.73	5.91
Gemini-3-Flash	54	43.35	64	61.30	6.39
MiMo-V2.5	34	23.76	50	55.43	6.58
Qwen3.6-27B	35	21.08	64	53.65	6.88

Table 4: VLM-backbone ablation under the same AgenticNav setting on the R2R-CE.

非常依赖模型自身能力



优点：给出了一种新的VLN任务选点方式，让VLM动作空间更自由，且简单易复现

缺点：对模型的要求太高，工具少且非常依赖模型自身的上下文长度以及工具调用能力



RAL 2026

DRIVE-Nav: Directional Reasoning, Inspection, and Verification for Efficient Open-Vocabulary Navigation

Maoguo Gao¹, Zejun Zhu², Zhiming Sun², Zhengwei Ma¹,
Longze Yuan¹ Zhongjing Ma^{1,3}, Zhigang Gao^{1,3}, Jinhui Zhang^{1,3}, and Suli Zou^{1,3,*}

¹Beijing Institute of Technology

²DeepBlue College

³The National Key Laboratory of Autonomous Intelligent
Unmanned Systems (KAIUS), School of Automation

代码暂未开源

Open-Vocabulary Object Navigation

开放词汇目标导航 (OVON)

给定一个自然语言指定的目标物体类别，智能体需要在未知环境中边探索边导航，并最终找到该类别的目标实例。

1. Frontier 候选冗余

现有方法生成的多个前沿点往往**属于一个实际探索方向**，但往往都把它们当作独立候选，导致VLM决策空间冗余、选择不稳定


2. Frontier 缺少边界之后的直接语义信息


Agent选择前沿点时往往没有真正看到前沿点后面的区域，只能根据几何或者已有局部语义来选择。
容易选错后回头

3. 不必要观察和大模型调用效率低

现有方法往往做360度观察，造成大量不必要的原地旋转

已探索边界线的**中点**作为前沿点






1. 多个属于同一分支的 frontier, 不再分别作为候选, 而是抽象成一个“持久方向”
2. Agent主动转向每个候选方向, 给VLM提供每个方向的RGB图
3. 提出240°规则, 作者认为, 后方的方向之前来的时候已经看过, 没有必要再转过去看

Directional Reasoning over Persistent Directions

把大量、瞬时的 frontier points, 转化成少量、稳定、可持续跟踪的方向级探索候选




1. 前沿点的生成逻辑没有变，依然是已探索(绿色)和未探索(白色)交接处生成
2. 基于FFM算法，从前沿点规划一条路径到当前点

传统FFM算法类似A*，寻找最短路径
DRIVE-Nav给出一种加权FFM算法：
从以下角度来计算最优路径：

1. 到达目标点的距离
2. 离障碍物的距离（避免靠墙）
3. 靠近自由空间中心线（尽量走中心）

Directional Reasoning over Persistent Directions

把大量、瞬时的 frontier points, 转化成少量、稳定、可持续跟踪的方向级探索候选



1. 前沿点的生成逻辑没有变, 依然是已探索(绿色)和未探索(白色)交接处生成

2. 基于FFM算法, 从前沿点规划一条路径到当前点


3. 以Agent当前位置为圆心画一个1m半径的圆, 取路径与圆的交点作为各候选方向

为什么使用加权FFM算法?

直接A*容易贴墙、经过障碍物边缘、不在走廊中心, 导致同一方向的前沿点产生的路径也不会重合

Directional Reasoning over Persistent Directions

把大量、瞬时的 frontier points, 转化成少量、稳定、可持续跟踪的方向级探索候选



4. 进行角度聚类, 把小角度差别的方向聚合成一个大方向 (相邻两个角度差大于 45° 时才认为是不同方向)

5. 对每个方向拍一张RGB图, 给VLM来选择方向

只会旋转去看身前240度的候选方向,
非必要不走回头路

6. 之后前往这个方向最远的前沿点

02 | 方法



按照选择的方向

每走一步(固定长度距离)

更新地图(包括前沿点、方向等)

没有异常

继续走下一步


异常情况:

1. 产生了新的方向
2. 选择的方向已经没有前沿点了
3. 发现目标(每一步都调用SAM3)

出现异常

VLM决策选择方向

出现新方向 (粉色)



Direction-Guided Prompt Enrichment

发现目标后如何更准确地定位目标

不直接把问题的目标类别送给SAM3, 而是让VLM生成更丰富、更适合视觉定位的目标描述, 再辅助SAM3分割

原始: 灭火器

丰富后: 安装在墙上的红色灭火器

Cross-frame Verification

防止单帧SAM3产生误检


在向目标走的过程中, 每一步获取到的RGB图片都要重新让VLM确认是不是目标, 只有连续三帧都确认了, 才认为是真的目标

TABLE I: Comparison with state-of-the-art methods on HM3D-OVON, HM3Dv2, and MP3D.

Method	Venue	Training-free	HM3D-OVON		HM3Dv2		MP3D	
			SR↑	SPL↑	SR↑	SPL↑	SR↑	SPL↑
SemExp [3]	CVPR'20	×	—	—	—	—	36.0	14.4
PONI [4]	CVPR'22	×	—	—	—	—	31.8	12.1
ZSON [5]	NeurIPS'22	×	—	—	—	—	15.3	4.8
CoW [6]	CVPR'23	✓	—	—	—	—	7.4	3.7
ESC [7]	ICML'23	✓	—	—	—	—	28.7	14.2
ActPept [22]	RAL'24	✓	—	—	—	—	39.8	17.4
UniGoal [21]	CVPR'25	✓	—	—	—	—	41.0	16.4
OpenFMNav [23]	NAACL-F'24	✓	—	—	—	—	37.2	15.7
L3MVN [8]	IROS'23	✓	—	—	36.3	15.7	—	—
InstructNav [24]	CoRL'24	✓	—	—	58.0	20.9	—	—
SG-Nav [12]	NeurIPS'24	✓	—	—	49.6	25.5	40.2	16.0
VLFM [9]	ICRA'24	✓	—	—	63.6	32.5	36.4	17.5
ApexNav [13]	RAL'25	✓	—	—	76.2	38.0	39.2	17.8
Dagger [25]	CVPR'23	×	10.2	4.7	—	—	—	—
DAGRL [25]	CVPR'23	×	18.3	7.9	—	—	—	—
RL [26]	ICLR'20	×	18.6	7.5	—	—	—	—
DAGRL+OD [2]	IROS'24	×	37.1	19.9	—	—	—	—
Uni-NaVid [27]	RSS'25	×	39.5	19.8	—	—	—	—
MTU3D [28]	ICCV'25	×	40.8	12.1	—	—	—	—
VLFM [9]	ICRA'24	✓	35.2	19.6	—	—	—	—
TANGO [29]	CVPR'25	✓	35.5	19.5	—	—	—	—
MSGNav [20]	CVPR'26	✓	48.3	27.0	—	—	—	—
DRIVE-Nav (Ours)	Ours	✓	50.2	32.6	72.4	41.3	41.8	22.6

除了在HM3Dv2上比不过ApexNav
其他数据集都有所提升
而且SPL(路径加权的成功率)提升很大

真机部署





优点：给出了一种新的VLN任务选点方式，用候选方向代替候选点

缺点：虽然有说240度不回头，但实际上如果一个方向走到头以后还是要回头的

Method	SR↑	SPL↑
w/o Weighted FMM	44.5	26.2
w/o Direction Tracking	45.3	26.2
w/o 240° Inspection View	45.5	26.8
Full Directional Reasoning Pipeline	46.3	27.5

Module				SR↑	SPL↑
Frontier	Directional	Prompt Enrich.	Verification		
✓				42.1	22.4
✓	✓			46.3	27.5
✓	✓	✓		48.0	28.9
✓	✓		✓	48.8	30.8
✓	✓	✓	✓	50.2	32.6

1. 购买UE场景并转换为airsim场景，可用键盘控制飞行并打点
2. 成功往UE场景中添加自定义物体模型
3. 完成新场景点云构建脚本
4. 旧场景路径规划脚本初版完成，包括前视、俯视和机器狗视角
5. 旧场景选出来30个地标，生成30条路线（随机点出发去地标的路线）



新加入的白车

下一步计划

在地标周围放置各种物体，并打点获取坐标

路径规划脚本适配新场景

基于路径内容，用VLM批量生成问题