



EMNLP 2025

CityEQA: A Hierarchical LLM Agent on Embodied Question Answering Benchmark in City Space

Yong Zhao^{†,1} Kai Xu^{†,1} Zhengqiu Zhu^{*,1} Yue Hu¹ Yatai Ji¹
Zhiheng Zheng² Yingfeng Chen² Chen Gao^{*,2} Yong Li² Jincan Huang¹

¹National University of Defense Technology

²Tsinghua University

<https://github.com/tsinghua-fib-lab/CityEQA.git>
Proceedings of EMNLP 2025, pages 12465-12480

具身问答（EQA）研究长期聚焦于室内环境，城市空间中环境、动作与感知的复杂性尚未被充分探索。将 EQA 扩展到开放城市空间，对自主系统、城市区域画像与城市规划等应用至关重要，但也带来三大挑战。

环境复杂且物体歧义：大量物体视觉相似，需结合地标与空间关系定位目标

跨尺度空间中需平衡长距离路径规划与细粒度移动和角度控制

感知复杂性：物体外观随距离、朝向与视角剧烈变化，影响答案生成的准确性

	Platform	Reference	Place	Open Vocab	Active
EQA-v1	House3D	(Das et al., 2018)	Indoor	✗	✓
IQUAD	AI2-THOR	(Gordon et al., 2018)	Indoor	✗	✓
MP3D-EQA	Matterport3D	(Wijmans et al., 2019)	Indoor	✗	✓
MT-EQA	House3D	(Yu et al., 2019)	Indoor	✗	✓
K-EQA	AI2-THOR	(Tan et al., 2023)	Indoor	✗	✓
HM-EQA	HM3D	(Ren et al., 2024)	Indoor	✗	✓
S-EQA	VirtualHome	(Dorbala et al., 2024)	Indoor	✗	✓
NoisyEQA	-	(Wu et al., 2024)	Indoor	✓	✓
OpenEQA	ScanNet/HM3D	(Majumdar et al., 2024)	Indoor	✓	✓
City-3DQA	-	(Sun et al., 2024)	Outdoor	✓	✗
EarthVQA	-	(Wang et al., 2024)	Outdoor	✓	✗
Open3DVQA	-	(Zhan et al., 2025)	Outdoor	✓	✗
CityEQA-EC	EmbodiedCity	-	Outdoor	✓	✓

1提出CityEQA-EC

构建了城市空间具身问答的首个

CityEQA-EC 基准数据集

1·1,412 个人工标注任务，覆盖六类开放词汇问答

2·基于真实感 3D 城市模拟器

EmbodiedCity 构建

3·以地标与空间关系指定期望答案，符合人类提问习惯

2提出PMA 智能体

提出分层智能体框架，使智能体具备长时程规划与分层执行能力

1·Planner 将问答分解为导航、探索、收集三类子任务

2·Manager 维护认知地图支撑空间推理



Invalid Question: What color is the car?

CityEQA Question: There is a **building** to the **south** of **you**. To the **east** of the **building** is a **shop** with a **yellow** signboard. Please tell me **What** color is the car parked in front of the shop?




To answer the question, I have a plan...

Ok, I will take care of the whole process...




building_1 is to my south...I find it!

Step 2



I'm going to the east side of the building_1, because that's where the target might be.

Step 7



Step 32

C In front of the shop_1, Let me see what color is the car... **The car is red!**




Step 14

E I need to find the shop_1 ... Oh, I find it!



03 | 城市空间具身问答基准与数据统计的构建过程 (CityEQA-EC)



Step1. 标注员在EmbodiedCity中自由探索，基于RGB观察生成开放词汇问答对，并记录观察与目标位姿。

Step2. 初始位姿设置在目标物体200米范围内以地标与空间关系补充问题描述，确保答案唯一；每个原始任务扩展出至少4个任务实例

Step3. 两名评审独立验证问题的可答性与答案准确性，最终保留1,412个高质量任务实例

03 | 城市空间具身问答任务的形式化与评测设置 (CityEQA-EC)

任务形式化

四元组定义

每个任务实例定义为四元组 ξ :

$\xi = (e, q, y, p_0)$ e : 场景 q : 问题 y :
答案 p_0 : 初始位姿

交互与优化目标

智能体从初始位姿出发逐步探索, 每步获取
RGB 图像与深度图组成的观测

基于观测生成答案 $\hat{y}$

目标: 以最少的步数生成高质量答案
答案质量由 LLM 裁判评分, 辅以导航误差 NE
与平均步数 MTS 评测。

数据集构建


基于 EmbodiedCity (Unreal Engine 4 + AirSim) 的真实感 3D 城市环境, 由五名标注员两步完成采集。

六类开放词汇任务

覆盖物体识别、属性识别、计数、存在判断、空间推理与世界知识六类问答

评测设置


因API 限制随机选取 200 个任务实验, 采用 QAA、NE、MTS 三项指标



Planner 模块.

利用预训练的大语言模型（LLMs），设计了一种小样本提示策略，将任务分为三个子任务：


- (1)数据采集子任务：用于收集所需信息；
- (2)目标识别子任务：用于识别地标或目标对象；
- (3)导航子任务：用于高效访问特定区域，从而缩小探索范围。



Observation--Map模块

根据当前无人机位置，获取到的depth和rgb维护一个地图：

- 1) 利用SAM对rgb图片中的地标进行分割和标记，同时映射到depth中进行合成，取得pcd文件。
- 2) 将pcd文件投影到2d地图上并通过算法去重，保证地图上物体的唯一性。



Manager 模块.

接受来自记忆、Map、Planner模块的输出，对无人机的探索进行管控

Memory模块

保存记录到的信息、物体信息、历史操作信息。

Answer Generation模块

进行答案的最后输出

Actor模块：将无人机的行动模式分为三个种类1) 导航者、2) 探索者、3) 收集者；每一时间步切换，对无人机探索进行指导，逐渐完成任务

	QAA (1-5) ↑	NE (m) ↓	MTS ↓
Blind Agents			
GPT-4	1.90±1.64	-	-
Qwen-2.5	2.34±1.88	-	-
LLaMA-v3.1-8b	2.31±1.72	-	-
DeepSeek-v3	2.03±1.41	-	-
Socratic Agents (VLM/LLM)			
GPT-4o/GPT-4	2.71±1.72	-	-
GPT-4o/Qwen-2.5	2.77±1.49	-	-
GPT-4o/LLaMA-v3.1-8b	2.70±1.71	-	-
GPT-4o/DeepSeek-v3	2.82±1.53	-	-


VQA Agents			
GPT-4o	4.37±1.35	-	-
Qwen-2.5	4.00±1.67	-	-
LLaVA-v1.5-7b	3.81±2.01	-	-
Exploring Agents			
RE	2.19±2.64	73.31±45.43	46.41±10.41
FBE	2.31±2.54	86.92±53.71	39.31±32.17
Human Agents			
H-VQA	4.87±0.72	-	-
H-EQA	4.94±0.21	38.72±40.87	9.31±6.32
PMA (ours)	3.00±1.96	46.56±36.39	24.44±14.39

在CityEQA-EC上的对比实验
PMA 问答准确率 QAA 3.00
超过全部自动基线，达人类
水平的 60.73%

导航效率
PMA 导航误差 46.56 m、平均
步数 24.44，远低于 RE 与 FBE
基线

	QAA (1-5) ↑	NE (m) ↓	MTS ↓
PMA w/o map	2.31±1.82	76.41±48.64	43.27±31.92
PMA w/o navigator	2.33±1.64	68.31±46.91	38.83±27.71
PMA w/o explorer	2.68±1.87	57.13±41.43	20.62±15.11
PMA	3.00±1.96	46.56±36.39	24.44±14.39

PMA 各模块的消融实验
移除认知地图后性能下降最大 (QAA 2.31)



Collector 随收集步数增加使
NE 下降、QAA 上升，最频繁
动作为KeepStill，验证观测调
整有效



AAAI 2026

Expand Your SCOPE: Semantic Cognition over Potential-Based Exploration for Embodied Visual Navigation

Ningnan Wang Weihuang Chen* Liming Chen Haoxuan Ji Zhongyu Guo Xuchong Zhang Hongbin Sun
Institute of Artificial Intelligence and Robotics, Xi'an Jiaotong University

<https://github.com/mrwangyou/SCOPE>


现有的大多数**零样本导航方法**通过融入**记忆机制**来增强探索，以支持目标导向的行为。然这些方法展现出一一定前景，但它们面临**两个主要局限**

1) VLM对3D空间理解不足

它们未在密集3D输入上训练，难以准确理解复杂空间关系。

2) 记忆系统忽略未探索区域的连接价值

多数记忆仅关注已访问区域，无法将当前观测与未访问但可能与目标相关的区域联系起来，导致智能体缺乏明确的探索方向。



本文重点聚焦EVN即具身导航任务

本文提出的方法具有以下两个重要特性

1) 零样本

使智能体能够在未知环境中运行而无需针对特定任务进行微调，而是利用从大规模预训练中习得的可泛化知识。

2) 基于势能的边界探索

显式估算每个边界区域的语义效用，将其整合到一个结构化的时空势能图中


已探索区域包括:


- 1) 过去时间步的rgb-d图片
- 2) 已探索过的物体信息

用**边界快照**的方式标识
未探索区域

用**VLM**以三个维度对边
界快照进行评分并得到
总评分P:


- 1) 语义丰富度
- 2) 可探索性
- 3) 目标相关性





输入潜力评分和结构化记忆
输出一个动作，对应着记忆快照和物体对或者一个待探索的边界快照

$$E_{m,n} = (\omega_{\text{pot}} \cdot P_{m,n} + \omega_{\text{sem}} \cdot p_{m,n}^{\text{sem}} + \omega_{\text{explore}} \cdot p_{m,n}^{\text{explore}} + \omega_{\text{goal}} \cdot p_{m,n}^{\text{goal}}) \cdot \frac{1}{1 + \gamma \cdot \mathbf{n}_{m,n}}, \quad (9)$$



细化与反思

当选择记忆快照和物体对时，触发细化，动作交给vlm审查，审查不通过则重新调用主机制直到审查通过或者重复次数达到上限

势能估计提示词



...Your task is to analyze whether exploring this frontier would help the robot achieve its goal. ... Use EXACTLY this format: ...
Definitions: ...
Example output: ...

SEMANTIC RICHNESS: High
EXPLORABILITY: Medium
...




自我反思提示词



...Your task is to validate whether your previous selection is correct given the question and the snapshot you chose. You previously selected ...

Choice **REJECTED**
... ..





Method	GOAT-Bench			
	FR	FI	SR	SPL
SenseAct-NN Skill Chain	—	—	29.5	11.3
SenseAct-NN Monolithic	—	—	12.3	6.8
CoW (2023)	—	—	16.1	10.4
DyNaVLM (2025)	—	—	25.5	10.2
VLMnav (2024)	—	—	16.3	6.6
Modular GOAT (2024b)	—	—	24.9	17.2
Explore-EQA (ICRA’2024b)	✓	—	55.0	37.9
CG + Frontier (ICRA’2024)	✓	—	61.5	41.3
TANGO (CVPR’2025)	—	—	32.1	16.5
MTU3D (ICCV’2025)	✓	—	47.2	27.7
3D-Mem (CVPR’2025)	✓	—	69.1	48.9
SCOPE (Ours)	✓	✓	73.7	53.5

Method	A-EQA			
	FR	FI	Corr.	Eff.
LLaVA-1.5 Frame Captions	—	—	38.1	7.0
CG Scene-Graph Captions	—	—	34.4	6.5
SVM Scene-Graph Captions	—	—	34.2	6.4
Multi-Frame	—	—	41.8	7.5
Explore-EQA (ICRA’2024b)	✓	—	46.9	23.4
CG + Frontier (ICRA’2024)	✓	—	47.2	33.3
TANGO (CVPR’2025)	—	—	37.2	/
MTU3D (ICCV’2025)	✓	—	51.1	42.6
3D-Mem (CVPR’2025)	✓	—	52.6	42.0
SCOPE (Ours)	✓	✓	59.1	41.0






Figure 2: Performance across modalities on GOAT-Bench.






Figure 4: Calibration of 3D-Mem and SCOPE. “ECE” represents the estimated calibration error ($\times 100$), with lower values indicating better calibration. The dashed line denotes perfect calibration, and the bar colors become darker as they approach ideal calibration.

