arXiv:2511.10376v5，17 Mar 2026

MSGNav: Unleashing the Power of Multi-modal 3D Scene Graph for Zero-Shot Embodied Navigation

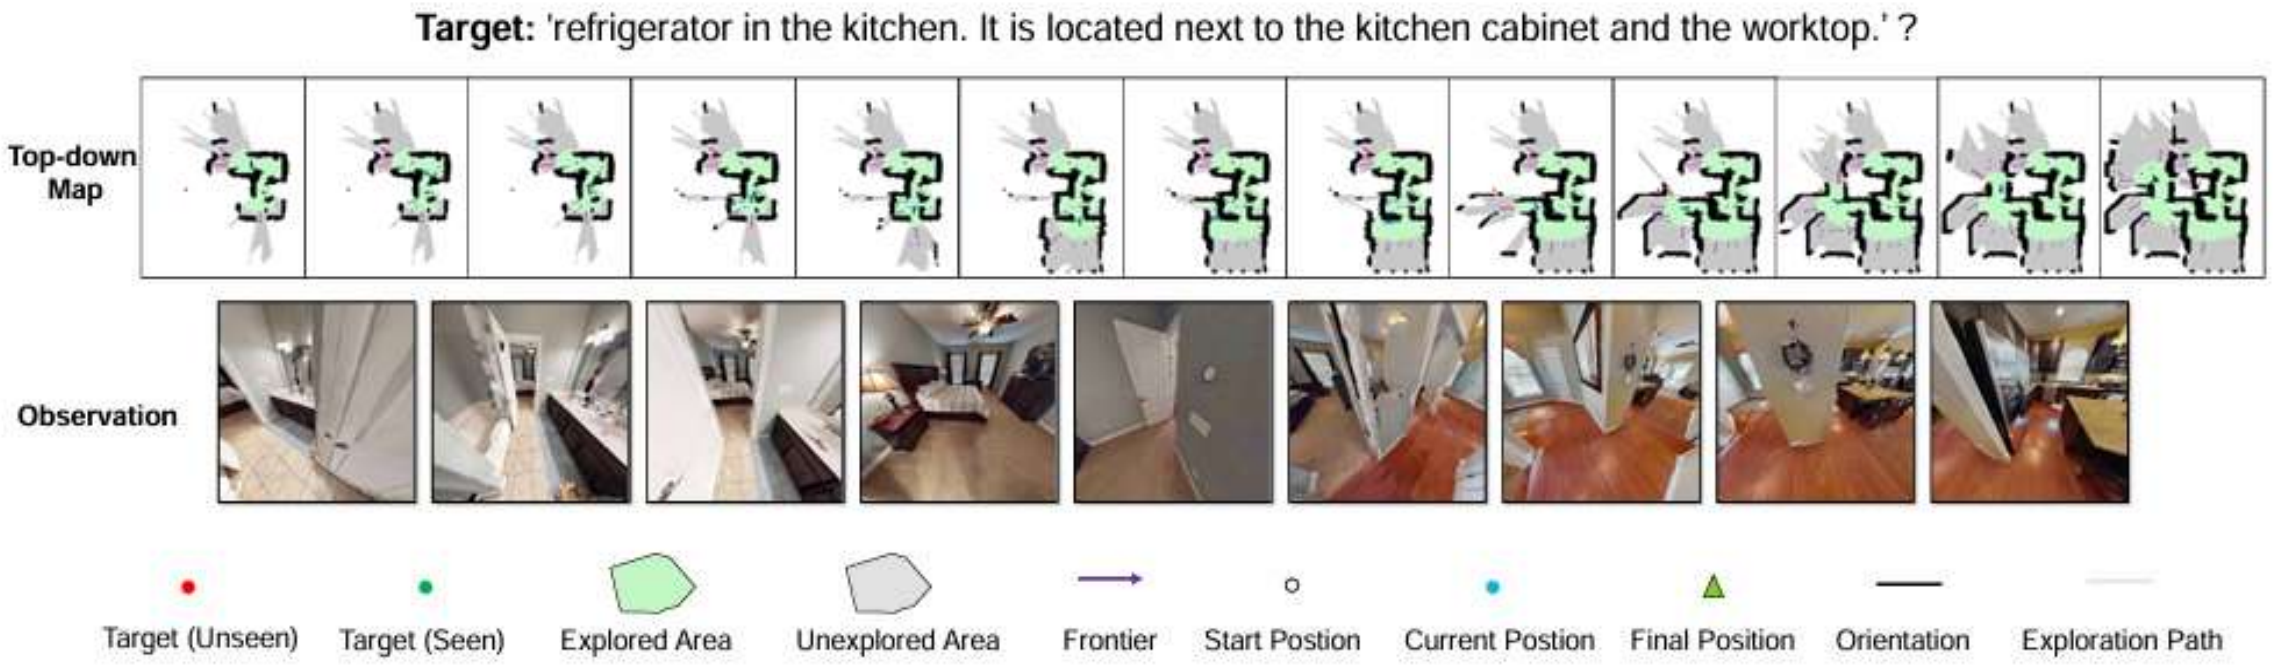
Xun Huang[1,2,6] Shijia Zhao[1,2] Yunxiang Wang[4] Xin Lu[5,6]
Wanfa Zhang[1,2] Rongsheng Qu[3,6] Weixin Li[3,6] Yunhong Wang[3,6] Chenglu Wen[1,2]

[1]Fujian Key Laboratory of Urban Intelligent Sensing and Computing, Xiamen University, China
[2]Key Laboratory of Multimedia Trusted Perception and Efficient Computing,
Ministry of Education of China, Xiamen University, China
[3]Beihang University, China [4]Nanyang Technological University, Singapore
[5]University of Chinese Academy of Sciences, China [6]Zhongguancun Academy, China

https://github.com/ylwhxht/MSGNav

任务： 在室内环境中智能体探索并导航至自然语言描述的目标，例如：“厨房里的冰箱，位于厨房橱柜和操作台旁边”。

如何完成任务： 机器人在未知或已经探索过一部分的环境中，利用已有的预训练模型，根据目标信息寻找物体。每走一步，它都会接收 RGB 图像和深度信息，再决定往哪里走。



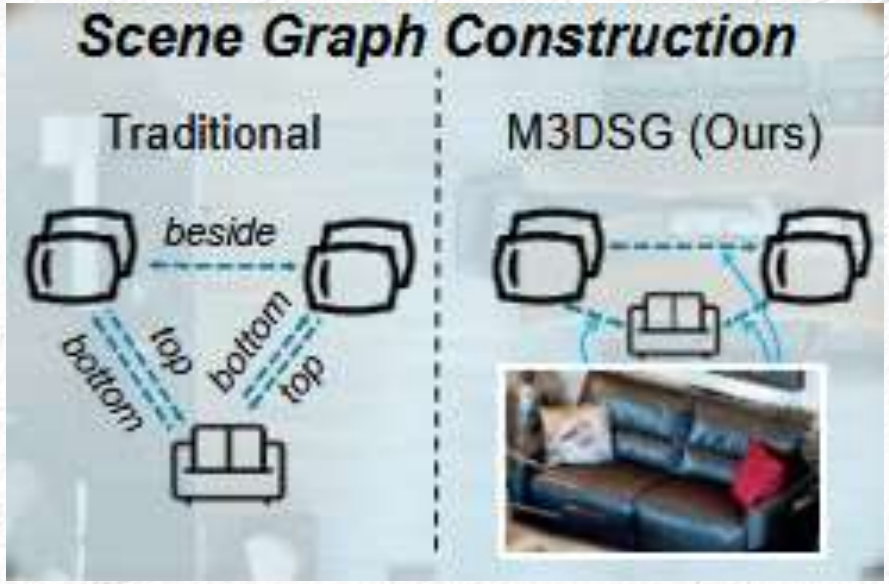
本篇论文主要针对三维场景的缺点进行优化。
传统三维导航三维构建的缺点如下：

解决：引用新结构：多模态三维场景图
M3DSG

1. 构建成本高。部分传统方法需要调用多模态大模型，对候选物体对进行语义关系推断。随着场景中物体和候选关系增多，推理时间和 Token 开销可能随之增加。

3. 词汇受限。现有方法中场景图受到预设词表限制，词表之外的新类别难以被记录出来。出现新的东西不能自动的导入。

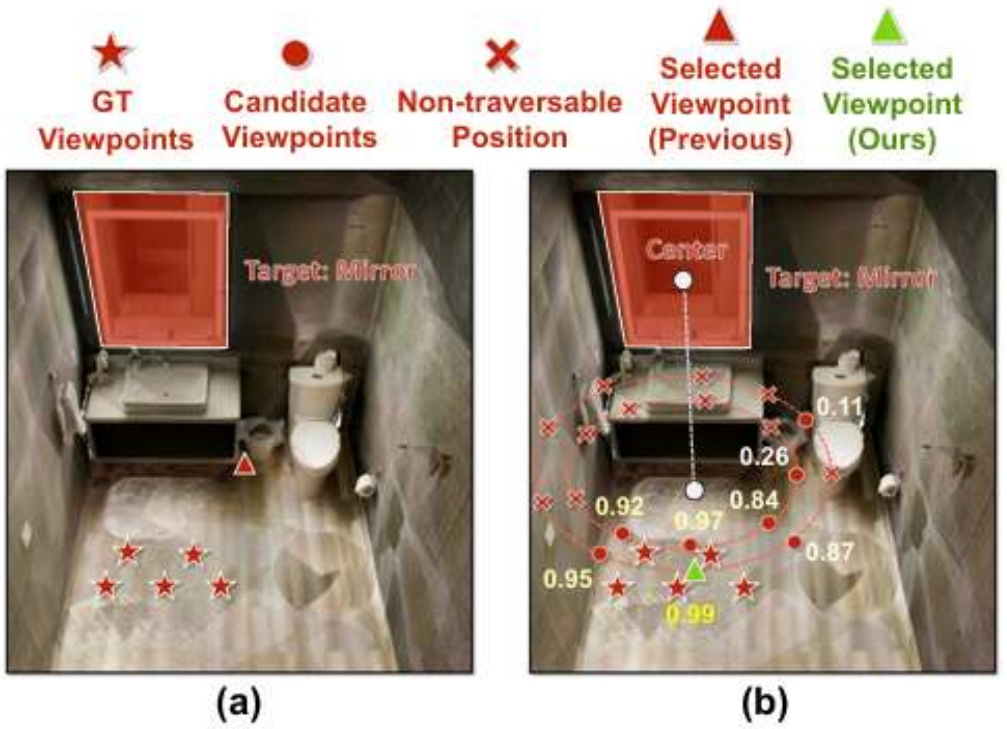
2. 视觉信息不足。在处理的过程中需要把图片信息转化为纯文字，会丢掉很多画面细节。物体一旦识别错了，后面的判断也会受到影响。比如：如果初次判断中图里的类别写成了电视，但其实他是壁画。对后续判断就会产生很大的影响。

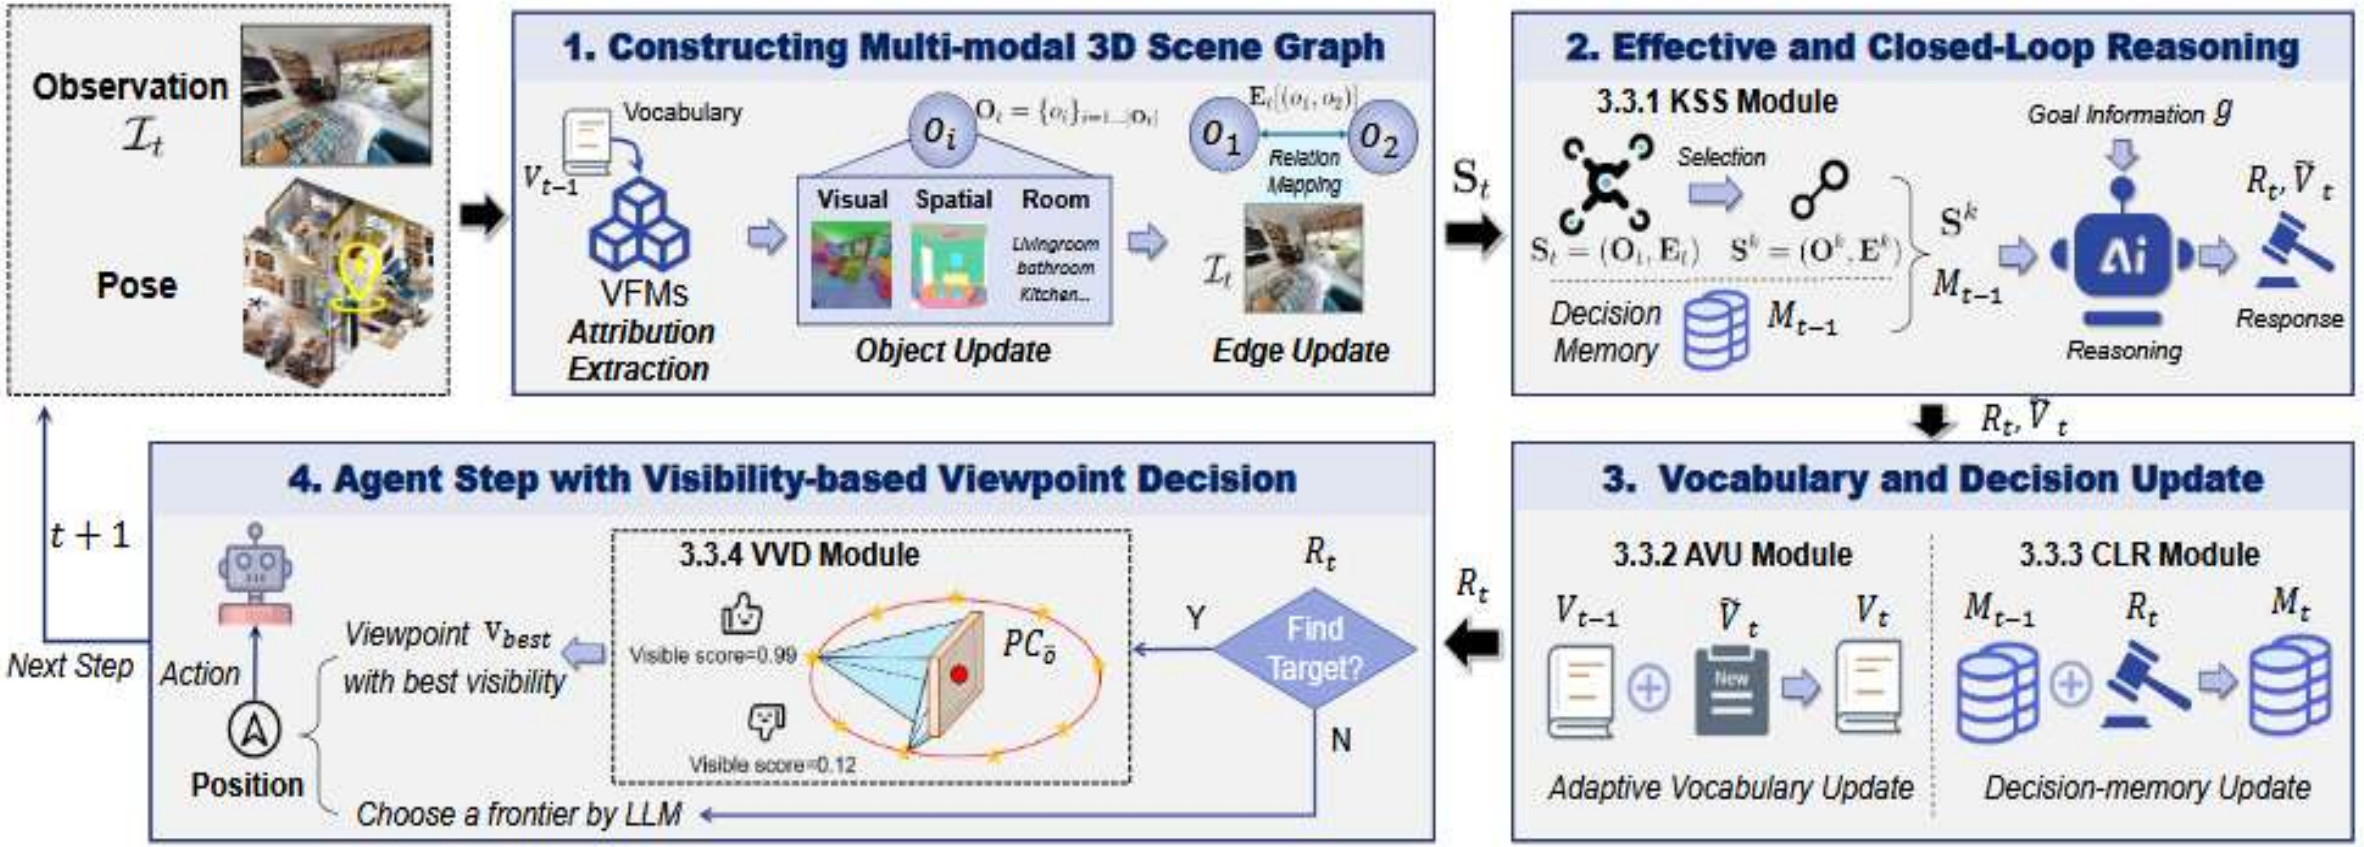


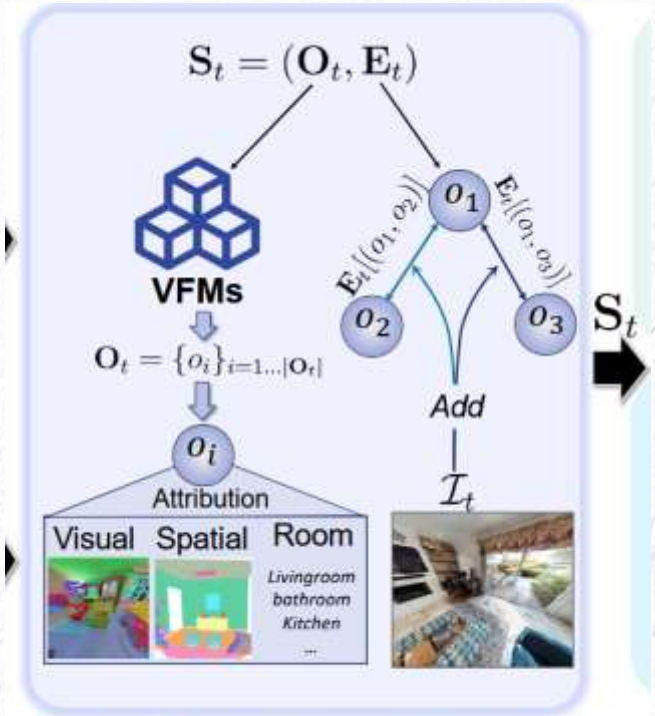
最后一公里问题：

1、找到目标后，还需要选一个合适的停靠位置。许多方法定位到目标后，就直接选择离目标最近的可通行位置。但这个位置的观察角度可能不好，目标也可能被其他物体挡住。即使已经走到目标附近，任务仍然可能失败。

2. 思路：已经知道目标在哪里，但还没有选好最后应该停在哪里。比较不同位置能看清多少目标，选择可见性更好的位置。引入了可见性视点决策VVD

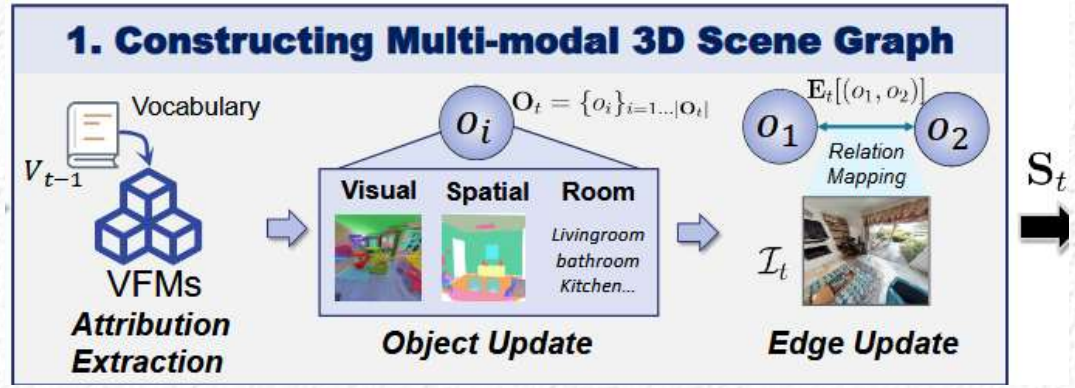



Observation
$\mathcal{I}_t$
Pose
1. Constructing Multi-modal 3D Scene Graph
Vocabulary
V_{t-1}
VFMs
Attribution
Extraction
O_i
$O_t = \{o_i\}_{i=1...|O_t|}$
Visual
Spatial
Room
Livingroom
bathroom
Kitchen...
Object Update
$E_t(o_1, o_2)$
O_1
O_2
Relation
Mapping
$\mathcal{I}_t$
Edge Update
S_t
2. Effective and Closed-Loop Reasoning
3.3.1 KSS Module
Goal Information g
Selection
$S_t = (O_t, E_t)$
$S^k = (O^k, E^k)$
S^k
M_{t-1}
Decision
Memory
M_{t-1}
Reasoning
$R_t, \tilde{V}_t$
Response
$R_t, \tilde{V}_t$
3. Vocabulary and Decision Update
3.3.2 AVU Module
3.3.3 CLR Module
V_{t-1}
$\tilde{V}_t$
New
V_t
M_{t-1}
R_t
M_t
Adaptive Vocabulary Update
Decision-memory Update
R_t
4. Agent Step with Visibility-based Viewpoint Decision
3.3.4 VVD Module
R_t
Y
Find
Target?
N
Visible score=0.99
Visible score=0.12
$PC_{\tilde{o}}$
Viewpoint v_{best}
with best visibility
Action
Position
Choose a frontier by LLM
$t+1$
Next Step



(a) Construction of M3DSG

S是场景图
O是物体集合。
E是边集合。（只要任意物体之间的距离小于θ就加入边）每个边属性里面存的是一组RGB-D图像
由程序来完成维护



M3DSG：物体节点的建立与更新

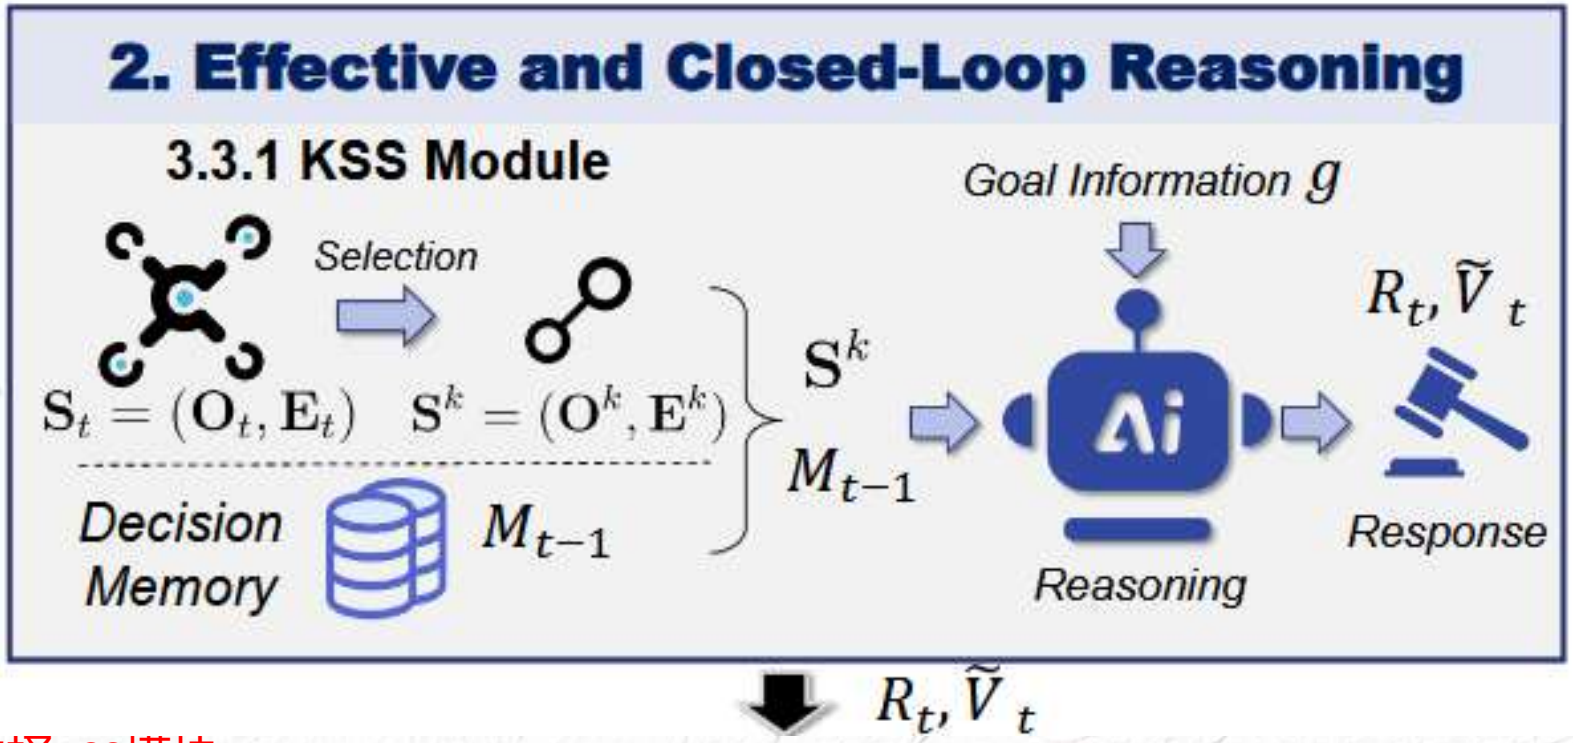
1．从当前画面提取物体信息。结合深度和位姿，获得物体的三维空间信息。

2．判断是不是之前见过的物体。根据空间位置和视觉特征进行匹配。如果是同一个物体，就合并信息；如果是新物体，就加入场景图。

3．持续更新物体节点。每个节点记录物体的编号、类别、三维位置、边界框、掩膜、点云、视觉特征和所在房间。

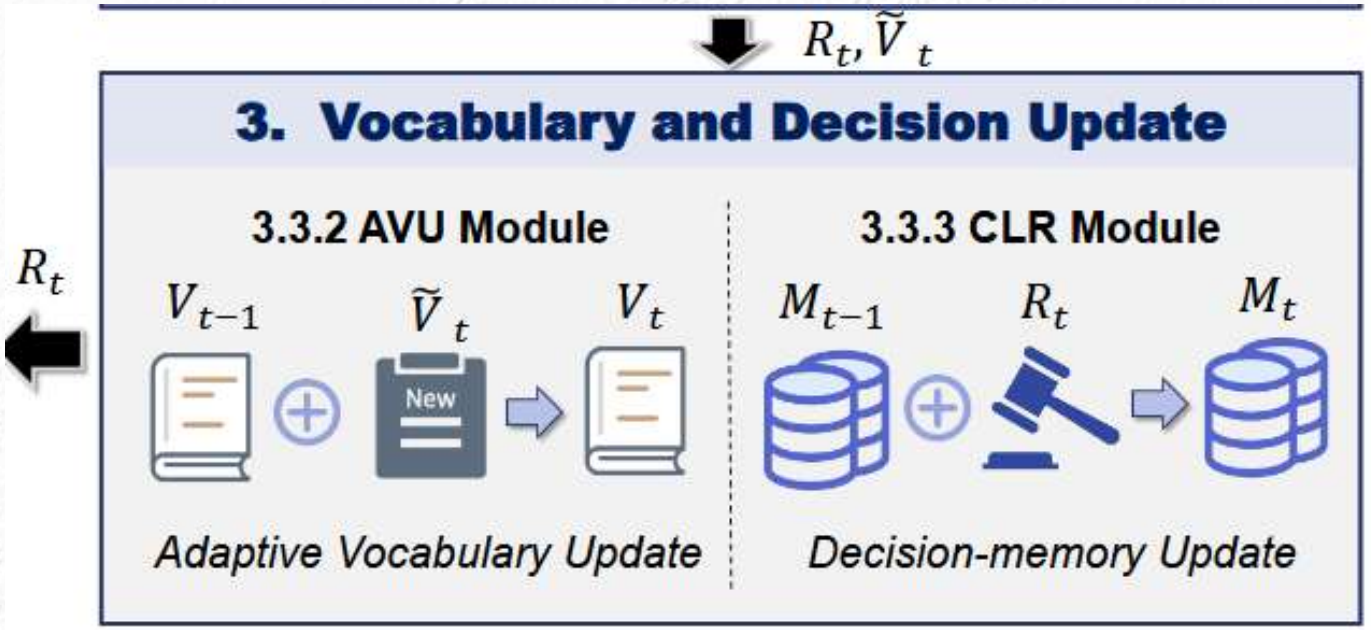
更新公式　$S_t = M(S_{t-1}, I_t)$

用当前 RGB-D 观测 I_t，更新上一时刻的场景图 S_{t-1}。



关键子图选择KSS模块：

探索范围扩大后，场景图中的物体和图像会越来越多。但当前任务通常只需要其中一部分信息，因此需要先筛选，再交给大模型推理。经过压缩--聚焦--剪枝的流程，使用贪心动态分配算法提取子图。选出关键子图输入VLM进行探索推理。



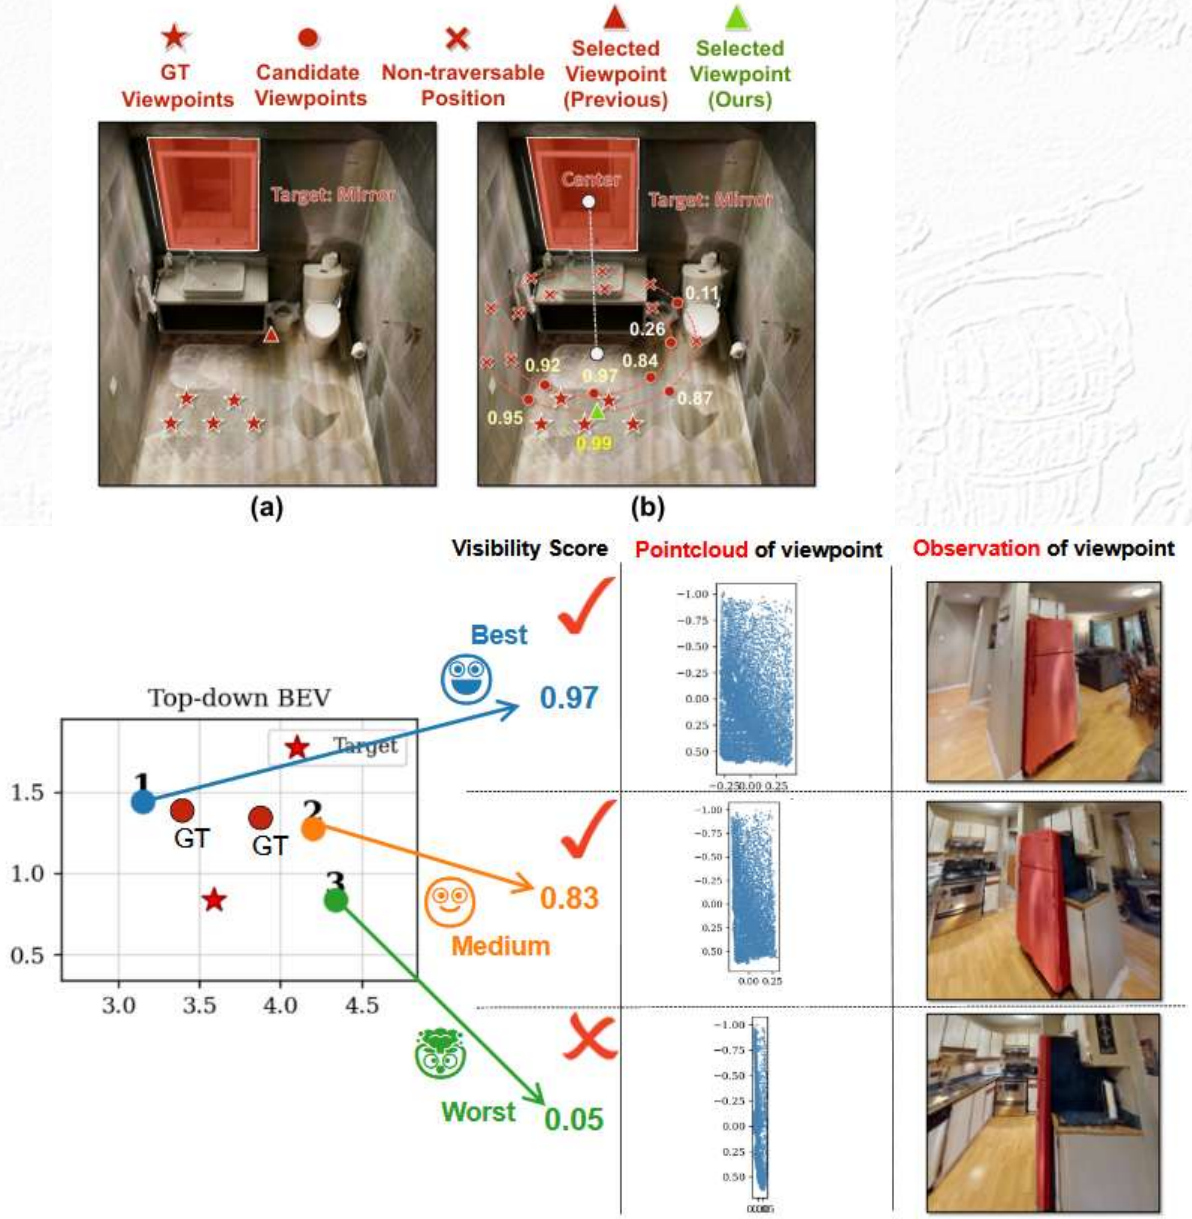
1．自适应词汇更新 AVU模块

系统以 ScanNet-200 作为初始词表。探索时，VLM 根据保留的图像提出需要补充的新类别，再将其加入词表。让后续感知和建图能够记录更多物体。

2．闭环推理 CLR模块

引入了记忆决策M。存在一个历史动作库。除了记录环境，系统还会保存过去的决策。当前推理同时参考目标、场景信息和历史选择，减少重复的错误决策。比如：上几步是做出的决策是什么，选择了那些物体，是否找到目标等等

02 | 方法：VVD如何选择最终停靠位置



1．生成候选位置

围绕目标，在不同距离和方向上采样。并去掉机器人无法到达的位置。

2．计算可见性

根据提前输入的场景点云检查是否存在遮挡。纯计算，没有调用大模型。（比较依靠场景点云的预输入）

3．选择最终位置

比较候选位置的可见性分数，选择分数最高的位置作为导航终点。

Method	Training-free	SR ↑	SPL ↑
SenseAct-NN Monolitic [19]	×	12.3	6.8
Modular CLIP on Wheels [19]	✓	16.1	10.4
Modular GOAT [19]	✓	24.9	17.2
SenseAct-NN Skill Chain [19]	×	29.5	11.3
VLMnav [8]	✓	20.1	9.6
DyNaVLM [18]	✓	25.5	10.2
3D-Mem† [43]	✓	28.8	15.8
TANGO [53]	✓	32.1	16.5
MTU3D [52]	×	47.2	27.7
MSGNav (Ours)	✓	**52.0**	**29.6**

Table 1. Experiments on the "*Val Unseen*" split of GOAT-Bench. "†" denotes the results we reproduced due to different settings.

Method	Training-free	SR ↑	SPL ↑
L3MVN [48]	✓	36.3	15.7
SG-Nav [44]	✓	49.6	25.5
InstructNav [28]	✓	58.0	20.9
CompassNav [26]	✓	59.6	26.9
Schrodinger'sNav [11]	✓	60.9	23.7
VLFM [46]	×	62.6	31.0
DORAEMON [10]	✓	66.5	20.6
WMNav [31]	✓	72.2	33.3
MSGNav (Ours)	✓	**74.1**	**33.4**

Table 2. Experiments on the HM3D-ObjNav benchmark.

SR:成功找到目标

SPL:路径长度加权的成功率

Module				Success Rate				SPL			
M3DSG	VVD	AVU	CLR	Overall	Category	Language	Image	Overall	Category	Language	Image
				28.8	29.9	26.8	29.5	20.2	21.0	18.7	21.0
✓				43.8	56.0	35.1	40.2	28.0	31.3	23.5	29.1
✓	✓			56.3	61.6	55.0	52.3	34.7	34.9	33.9	35.2
✓	✓	✓		55.3	58.6	51.7	55.7	36.7	**35.3**	**34.8**	40.1
✓	✓		✓	53.2	**64.6**	38.5	55.7	32.9	34.8	25.8	37.7
✓	✓	✓	✓	**60.0**	63.6	**57.2**	**59.1**	**37.0**	35.0	33.4	**42.6**

Table 3. Component ablation experiment across the first episode of each scene on the "*Val Unseen*" split of GOAT-Bench. The first row without any module, which represents our baseline model 3D-Mem [43] results. "VVD", "AVU", and "CRV" represent the Visibility-based Viewpoint Decision module, Adaptive Vocabulary Update module, and Closed-loop Reasoning and Verification module.

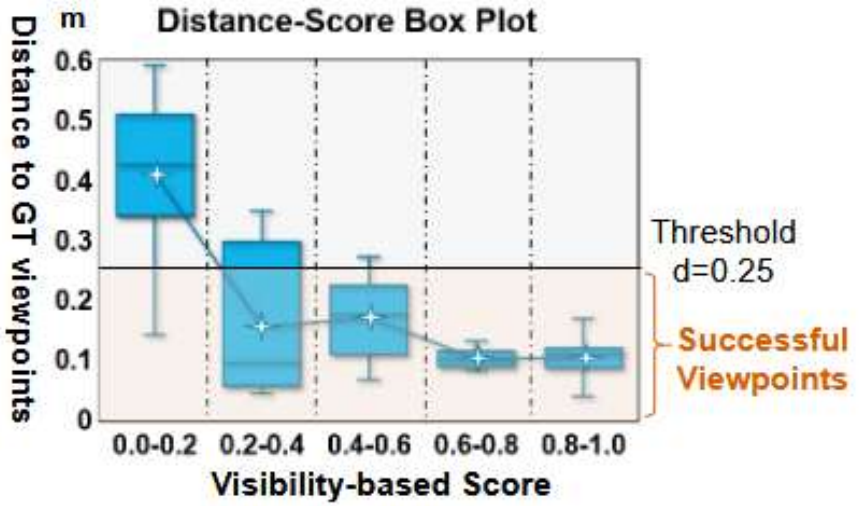
3D Scene Graph	Success Rate				SPL			
	Overall	Category	Language	Image	Overall	Category	Language	Image
Node-only	51.8	**63.6**	44.0	47.8	31.2	**39.3**	20.5	33.8
Traditional graph [9]	56.2	**63.6**	52.8	52.3	32.7	35.3	27.3	35.5
M3DSG (Ours)	**60.0**	**63.6**	**57.2**	**59.1**	**37.0**	35.0	**33.4**	**42.6**

Table 4. Scene graph experiment across the first episode of each scene on the "*Val Unseen*" split of GOAT-Bench. "Node-only" indicates Concept-graph [9] without object relation edges. "Traditional graph" indicates Concept-graph [9].

消融实验：
M3DSG 和 VVD 带来较大的成功率提升；
AVU 与 CLR 同时使用时，整体效果更好。

相比文字关系边，图像关系边对语言目标和图像目标更有帮助。

Success Threshold d (m)	Success Rate (MSGNav) w/o VVD	w/ VVD
0.25 (standard)	33.91	51.97
0.35	48.93	59.69
0.45	54.59	61.73
0.55	57.44	63.03
0.65	59.65	63.78
0.75	60.40	64.52
0.85	61.30	65.22
1.00	62.38	66.52



在 0.25 m 标准阈值下，加入 VVD 后，成功率从 33.91% 提高到 51.97%。

可见性分数较高的位置，通常更接近有效目标视点。VVD 改善了最终位置选择，但还没有完全解决最后一段导航问题。

优点和局限性

1．维护了一个新的数据结构，保留原始图像。后面还可以二次查看，有纠错空间。缺点：存储图片是否消耗空间。有反复读取图片的可能，图像存储和推理可能增加开销，具体需要测量。而且存储消耗也需要考虑。

2．把图片理解的时间点延后。通过相关子图筛选，减少推理需要处理的内容。一定程度上减小了算力消耗。然后调用大模型的次数降低，大部分交给了算法和计算。

3．目标选择更加慎重，用多种视点从多个角度进行观察。而且是用的数学计算来判断哪一个视点更为合适。降低推理负担。

疑问：最后一公里问题提出要找到目标的同时还需要一个合适的观察点，这是否是为了方便机器人的下一步类似于抓取的动作操作？如果是的，那视点的选择是否也跟操作的类型有关。不放到一起去研究吗。

疑问：已经存在边里的图是否能更新？存在里面的图是否经过裁剪之后会更好？有更好视角用不用更新？还是说大致估算出了距离。只需要知道有这个目标就行了。如果目标包含里面视点选择最后在做，如果不是目标做了是否无意义。