IEEE 2025

WMNav: Integrating Vision-Language Models into World Models for Object Goal Navigation

Dujun Nie[1,*], Xianda Guo[2,*,†], Yiqun Duan[3], Ruijun Zhang[1], Long Chen[1,4,5,‡1]
Institute of Automation, Chinese Academy of Sciences [2] School of ComputerScience,
Wuhan University[3] School of Computer Science, University of Technology Sydney [4]
IAIR, Xi'an Jiaotong University [5] Waytous

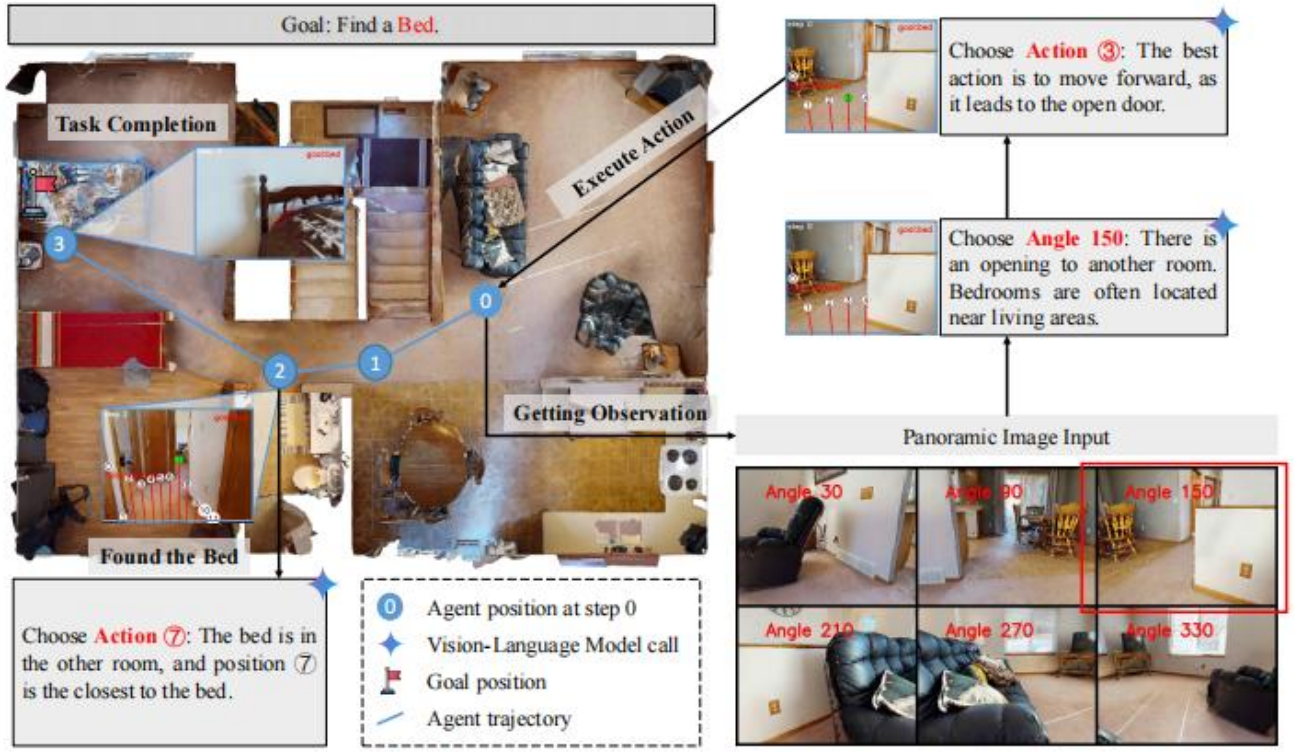
https://b0b8k1ng.github.io/WMNav/

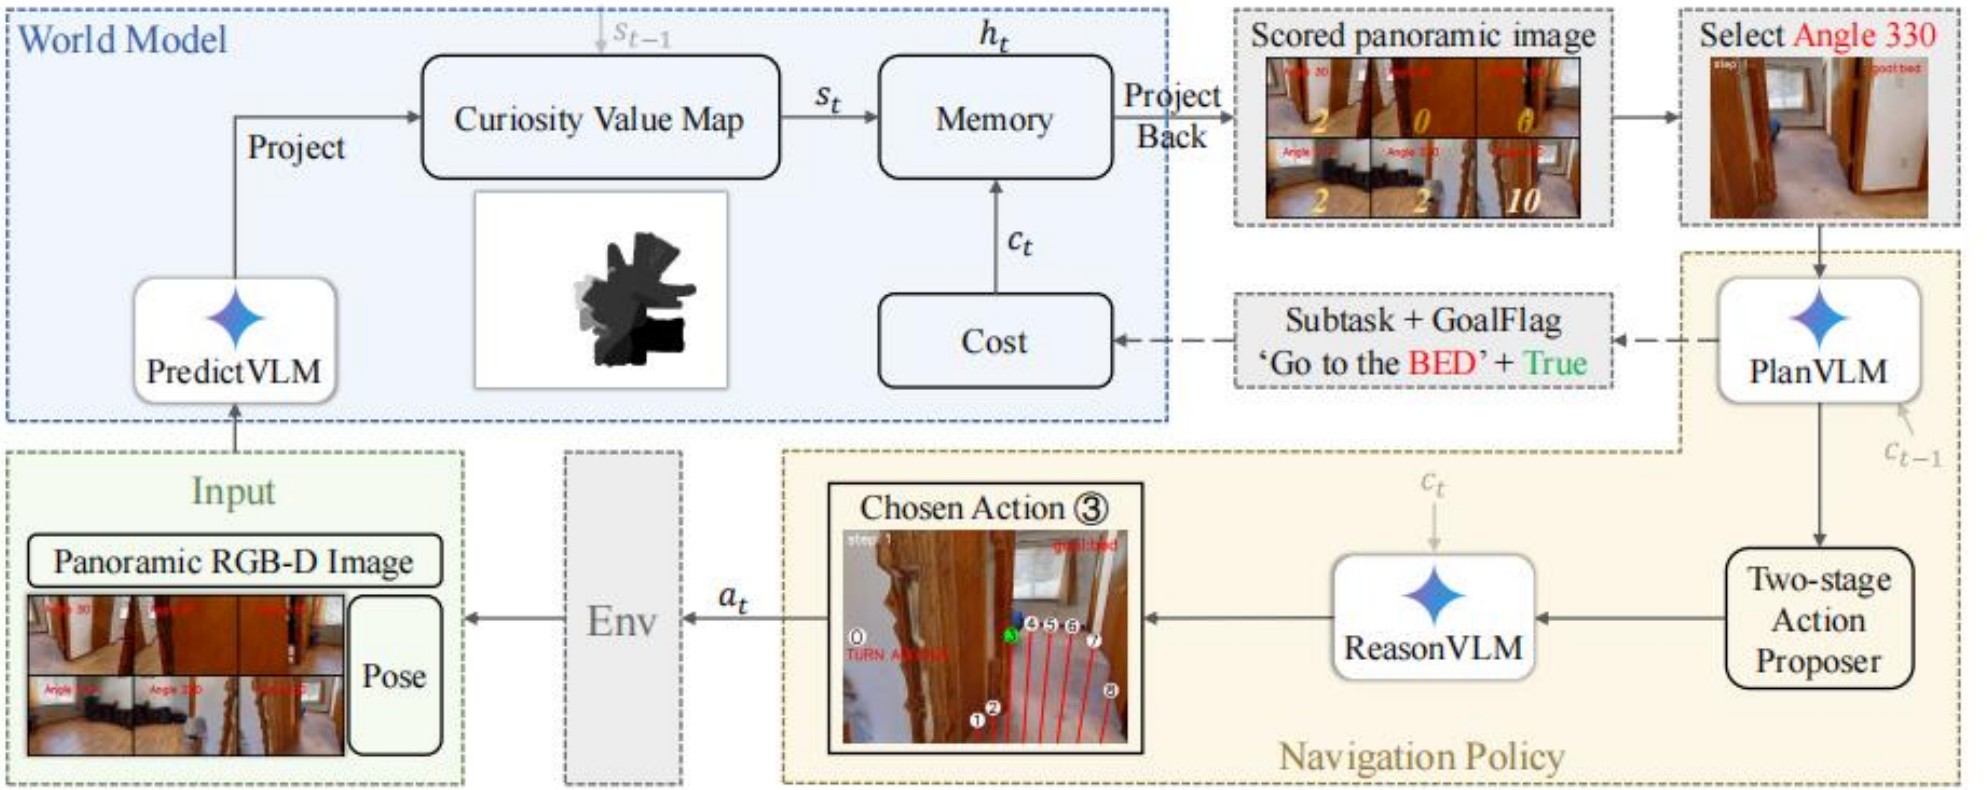
机器人只能看到局部场景，但需要决定去哪里寻找尚未出现的目标。 比如站在客厅找床，床不在视野里，机器人就必须根据门、走廊和房间布局，判断哪个方向更可能通向卧室。

没有充分发挥vlm的想象能力。大多数具身智能体都是根据观察行动，而难以利用常识去想象：走廊与沙发

历史信息利用不足。只根据当前图像判断，容易重复进入已经探索过、没有目标的区域，产生来回移动

VLM 决策不够可靠。可能产生幻觉、不断改变计划，也不擅长直接判断距离和停止时机





PredictVLM：好奇心地图构建

PlanVLM:子任务规划

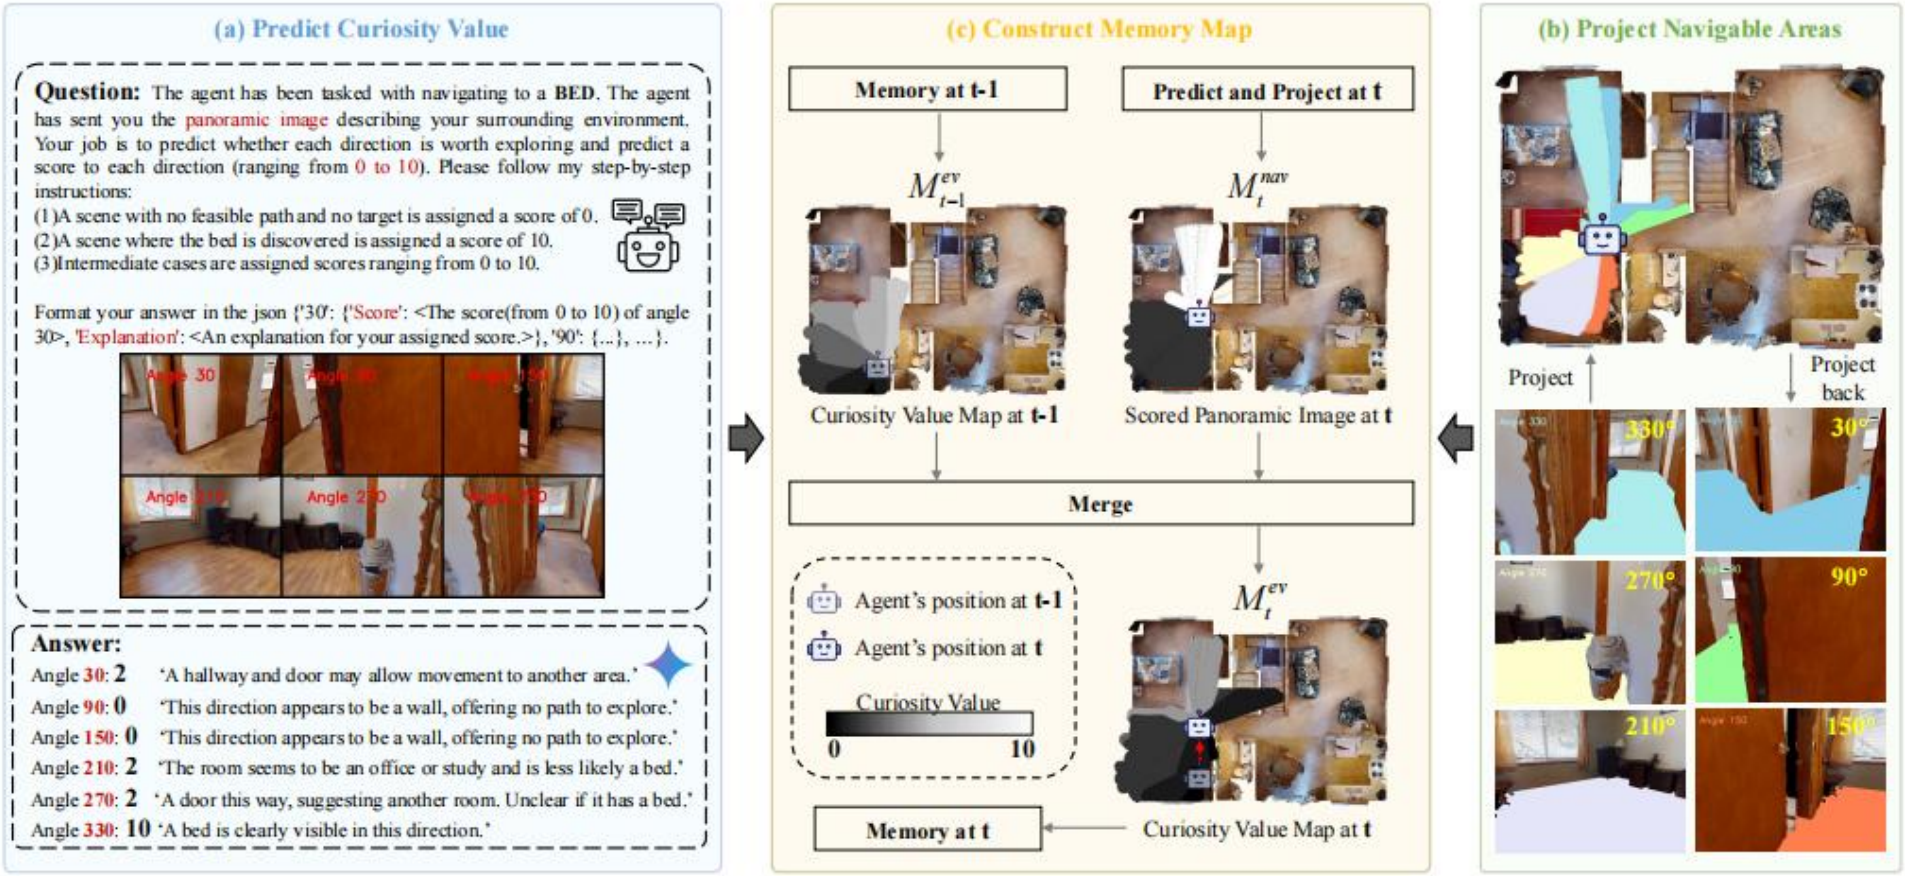
ReasonVLM:动作决策

世界模型：预测六个角度的方向是否值得探索，并结合历史地图选出最有价值的方向。

导航策略：接着制定下一步子任务，从候选位置中选择行动。

两阶段导航：发现目标后切换到精确接近阶段，最终到达目标附近并停止。

03 | Curiosity Value Map的构建



一、PredictVLM

对六个角度的画面进行探索价值打分并给出原因

二、对可通行区域的二维映射

通过RGB-D和当前位姿将可通行的地面区域映射到二维地图中（高度判断），以便后续对**Curiosity Value Map**的更新和维护，换个位置观察时，也能关联到之前的空间记忆

三、Curiosity Value Map构成

将**VLM的打分**和**可通行的二维地图**以及**历史地图**结合，生成新的**Curiosity Value Map**，维持历史低分区域和将已探索区域打低分以让智能体不会重复探索和突然改变探索方略

Plan Prompt

The agent has been tasked with navigating to a {goal}. It has sent you the following elements:
(1)<The observed image>: The image taken from its current location.
(2){Explanation}. This explains why you should go in this direction.

Your job is to describe next place to go. To help you plan your best next step, I can give you some human suggestions:
(1) If the {goal} appears in the image, directly choose the target as the next step in the plan.
(2) If the {goal} is not found and the previous subtask {Last Subtask} has not completed, continue to complete the previous subtask.
(3) If the {goal} is not found and the previous subtask {Last Subtask} has already been completed, determine a new subtask.

Format your answer in the json {'Subtask': <Where you are going next>, 'Flag': <Whether the goal is in your view, True or False>}.

Image Prompt



Configuration

goal: **bed**, Last Subtask: '**Go to the hallway**',

Explanation: '**This appears to be a hallway, which is a very likely place to find a bedroom.**'

PlanVLM:

Flag: False, Subtask: 'Go down the hallway'

GoalFlag：

输入得分最高的角度图像及其理由，**PlanVLM**判断是否已经发现目标物体，并将GoalFlag作为下一阶段的两阶段探索的依据。

PlanVLM负责子任务规划：

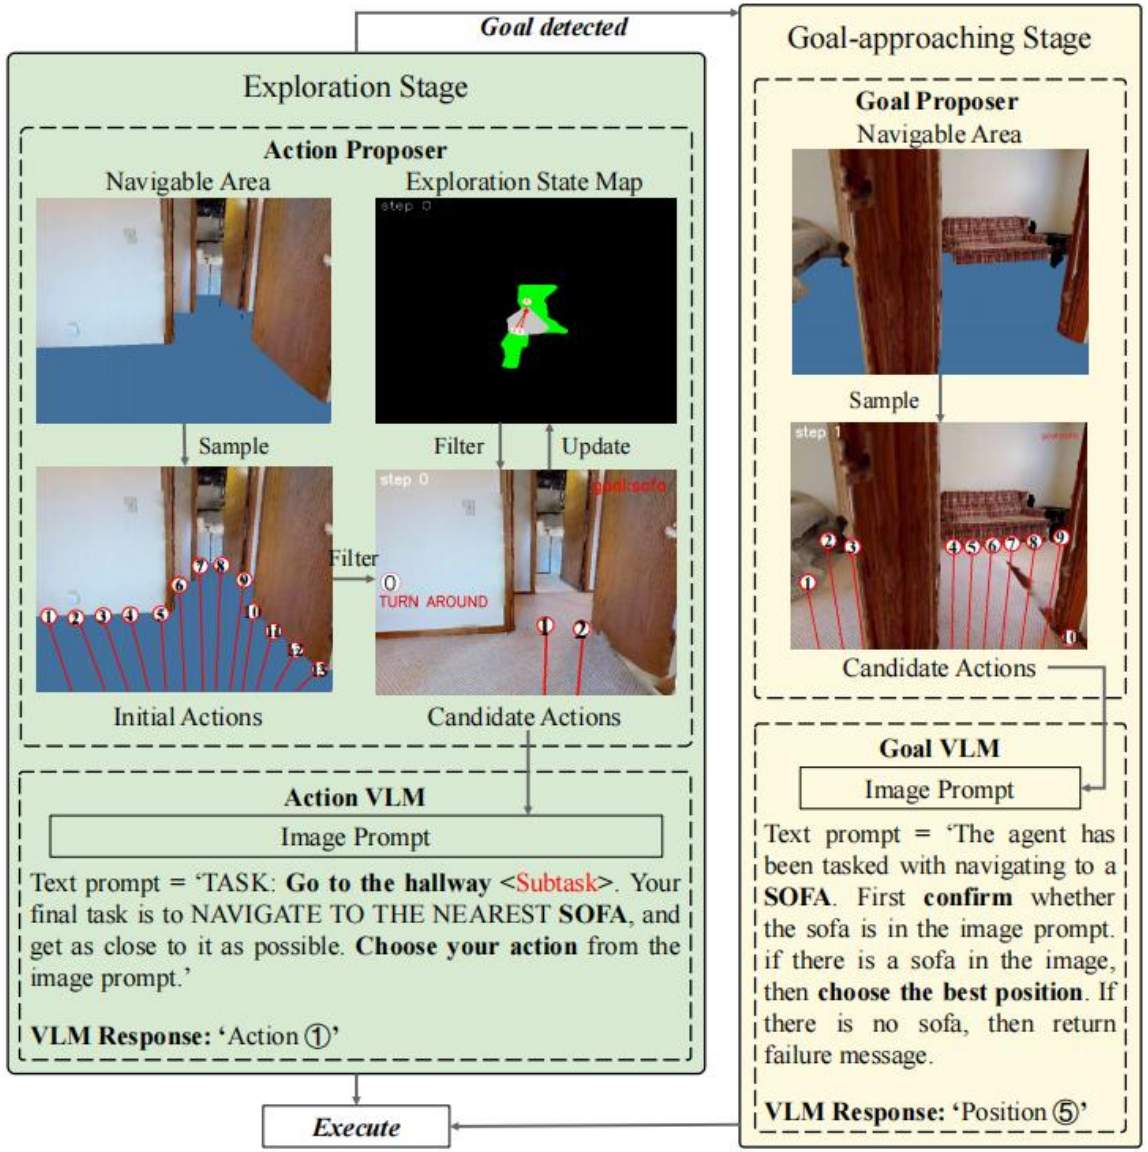
将一个大的任务划分为多个子任务，利用VLM自身的任务规划能力生成子任务来让Agent一步一步执行

子任务规划逻辑：

并非是在任务开始就完全规划，而是每一步都重新审查目前子任务是否完成

若未完成--->>接着完成

若已完成--->>规划下一步



动作候选的生成

两阶段共同点：

在原始图像中分角度采样，以不可通行区域的边缘作为边界

区分点：

探索阶段优先选择为探索的区域，并通过**按比例缩短向量长度**和**过滤过短的向量**来控制移动向量的长度，同时还要限制**探索距离小于1.7m。**

目标接近阶段不再限制探索距离和目标区域是否已探索，而且采样角度更密集

探索阶段：去哪里探索（保守）

目标接近阶段：目标具体在哪里

Model	TF	ZS	HM3D SR(%)↑	HM3D SPL(%)↑	MP3D SR(%)↑	MP3D SPL(%)↑
Habitat-Web [22]	✗	✗	41.5	16.0	31.6	8.5
OVRL [10]	✗	✗	-	-	28.6	7.4
OVRL-V2 [11]	✗	✗	64.7	28.1	-	-
ZSON [2]	✗	✓	25.5	12.6	15.3	4.8
PSL [39]	✗	✓	42.4	19.2	18.9	6.4
PixNav [12]	✗	✓	37.9	20.5	-	-
SGM [40]	✗	✓	60.2	30.8	37.7	14.7
VLFM [14]	✗	✓	52.5	30.4	36.4	17.5
CoW [4]	✓	✓	-	-	9.2	4.9
ESC [5]	✓	✓	39.2	22.3	28.7	14.2
L3MVN [27]	✓	✓	50.4	23.1	-	-
VoroNav [7]	✓	✓	42.0	26.0	-	-
OpenFMNav [8]	✓	✓	54.9	24.4	-	-
TopV-Nav [9]	✓	✓	45.9	28.0	31.9	16.1
WMNav(Ours)	✓	✓	**58.1**	**31.2**	**45.4**	**17.2**

此方法无需额外训练，在HM3D和MP3D上的性能相对强一些

	Memory	SD	TAP	SR(%)↑	SPL(%)↑
a	No	✗	✗	65.8	25.8
b	No	✓	✗	67.4	33.1
c	Text-Image	✓	✗	62.0	29.6
d	CVM(Ours)	✗	✗	69.5	**34.9**
e	CVM(Ours)	✓	✗	70.1	34.7
f	CVM(Ours)	✓	✓	**72.2**	33.3

SD：子任务分解

TAP：两阶段探索策略

Memory：记忆模式

Text-Image：图转文加俯视轨迹图

VLM	SR(%)↑	SPL(%)↑
Qwen2.5-VL-3B	29.7	15.8
Qwen2.5-VL-7B	46.1	20.7
Gemini 1.5 Flash	53.5	27.0
Gemini 2.0 Flash	57.9	30.7
Gemini 1.5 Pro	**58.1**	**31.2**

更换模型基座

ICLR 2026

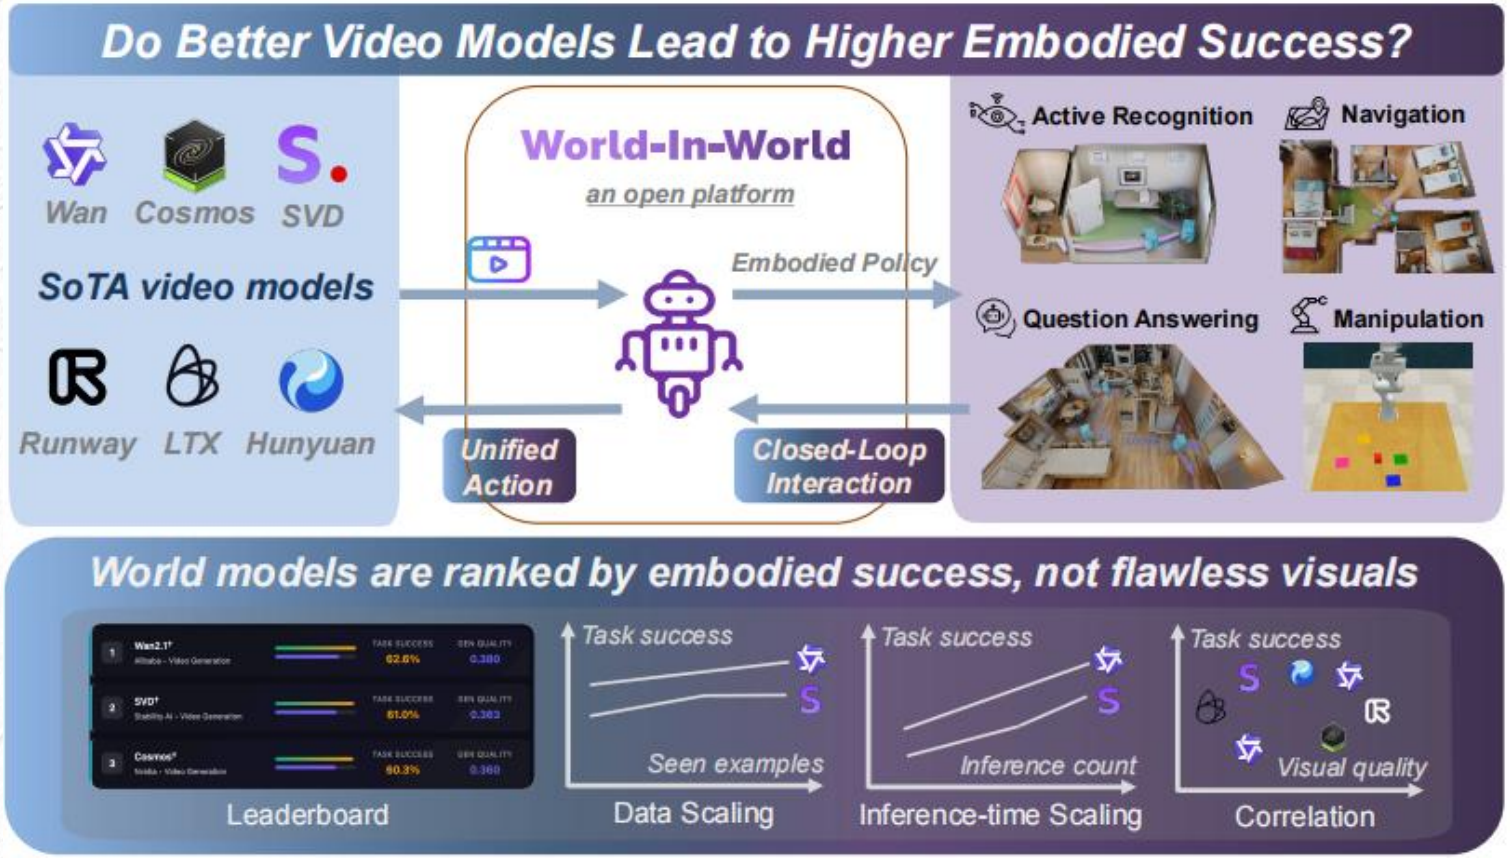
World-In-World: World Models in a Closed-Loop World

Jiahan Zhang[1,*],Muqing Jiang2,* ,Nanru Dai[1] ,Taiming Lu[1,3] Arda Uzunoglu[1]
Shunchi Zhang[1] Yana Wei[1]
Jiahao Wang[1] Vishal M. Patel[1] Paul Pu Liang[4] Daniel Khashabi[1] Cheng Peng[1]
Rama Chellappa[1] Tianmin Shu[1] Alan Yuille[1] Yilun Du[5]
Jieneng Chen[1,†]
[1]JHU [2]PKU [3]Princeton [4]MIT [5]Harvard
Project Page: https://world-in-world.github.io/

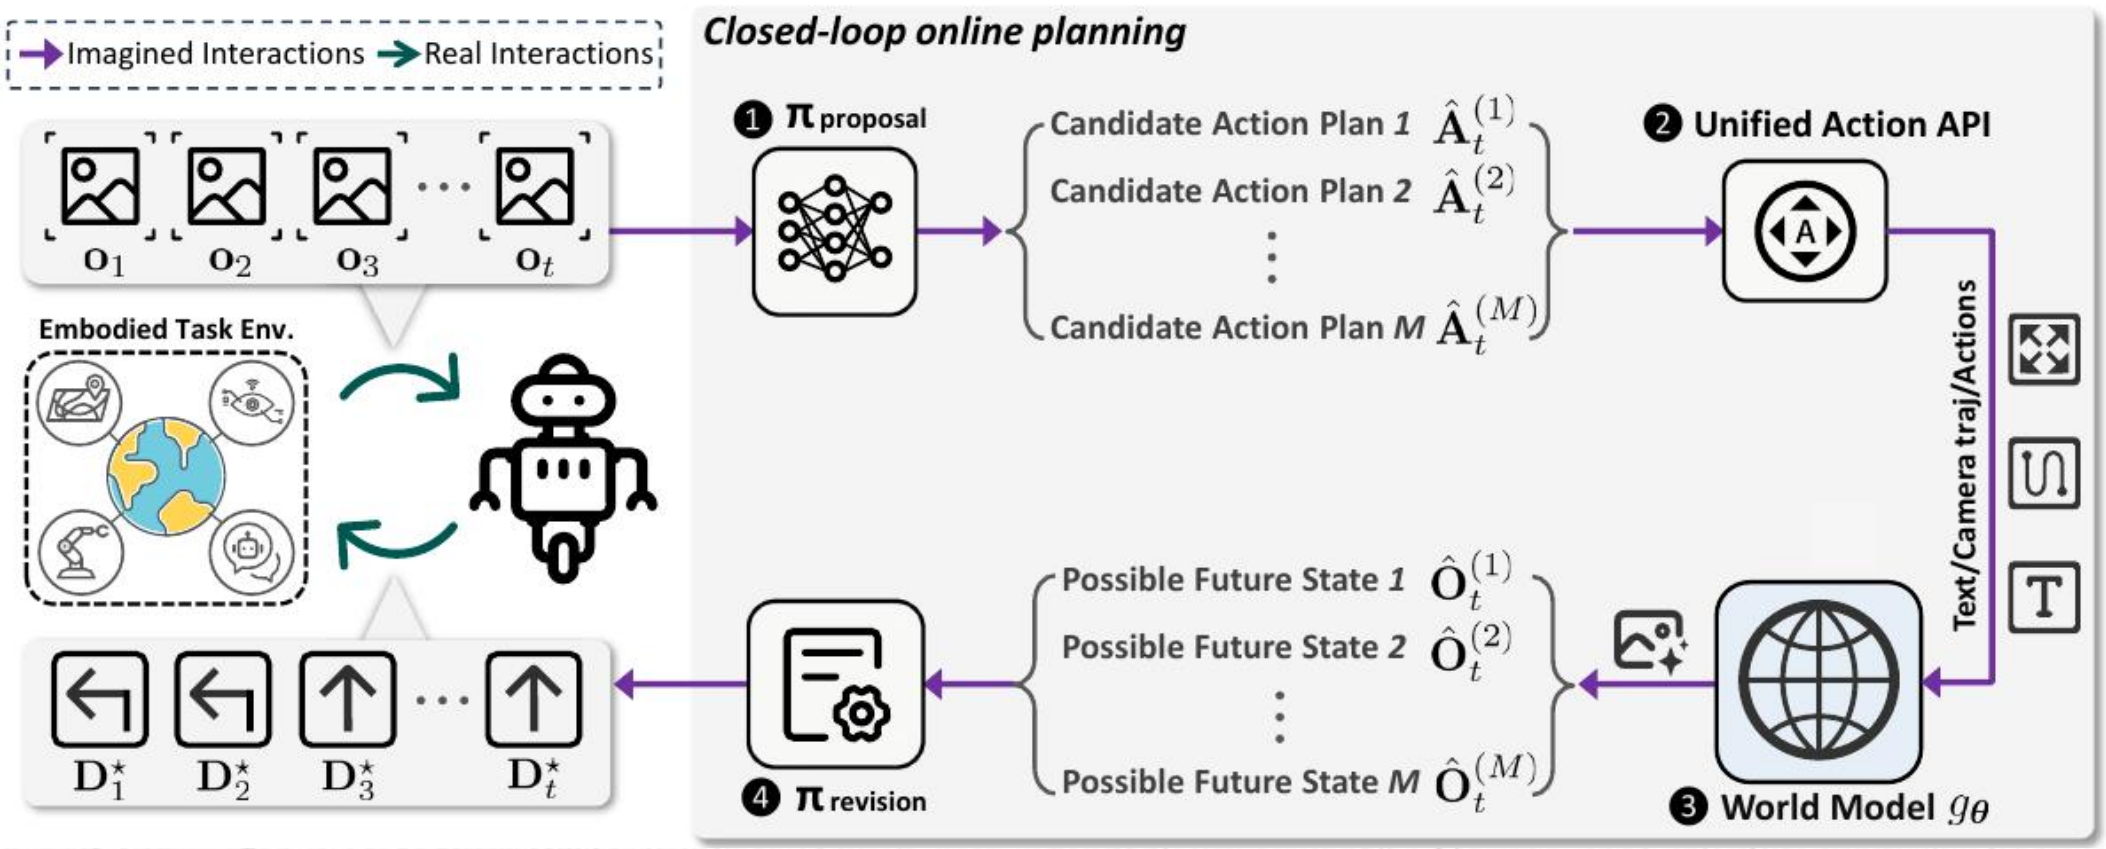
生成式世界模型（WMs）能够以极高的视觉真实感模拟世界，但我们要如何去评测其在具身领域的应用效果？

一、大多数现有基准以开环协议为主，只是孤立的测评WMs生成的视觉的质量，而非WMs解决具身问题的能力

二、本文提出了一个闭环测试平台和统一接口，将不同WMs接入测试平台来进行评测



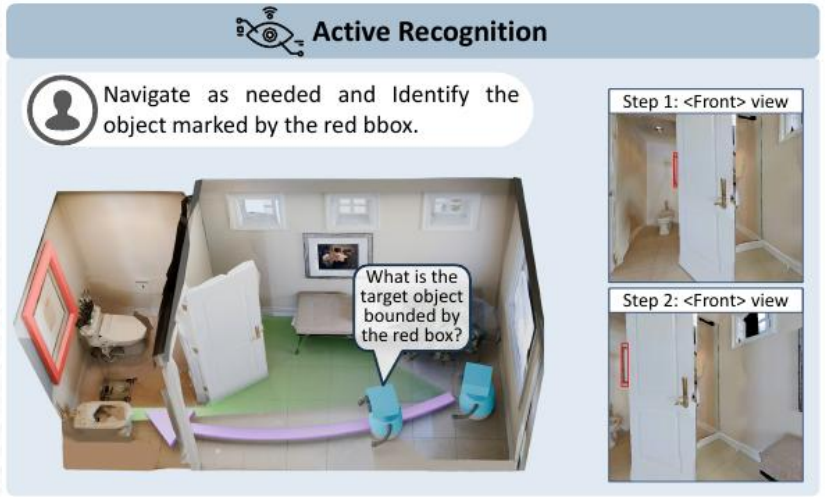
动作候选生成（qwen）：接收当前的前视图、全景图、可执行动作列表、任务描述和以及希望到达的位置的目标图像，根据当前任务类型生成候选动作方案。



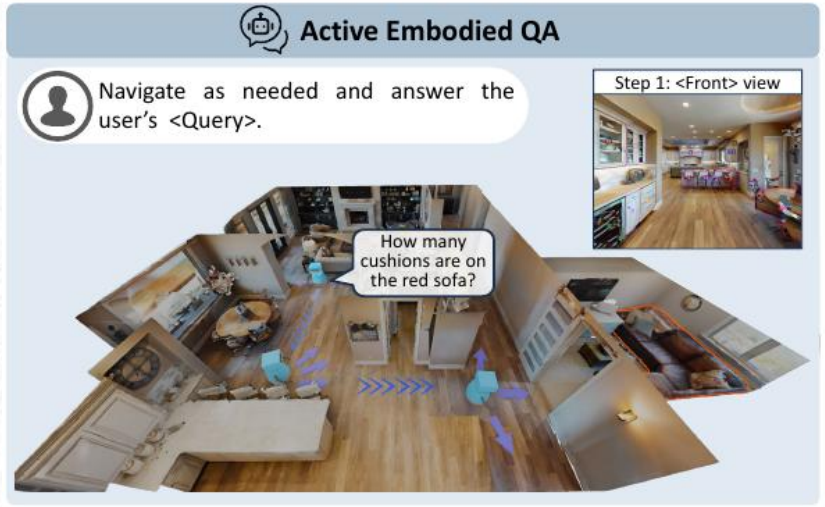
Unified Action API：通过同一动作接口将任务候选动作转换成世界模型可以理解的输入格式（文本、相机轨迹、离散动作）

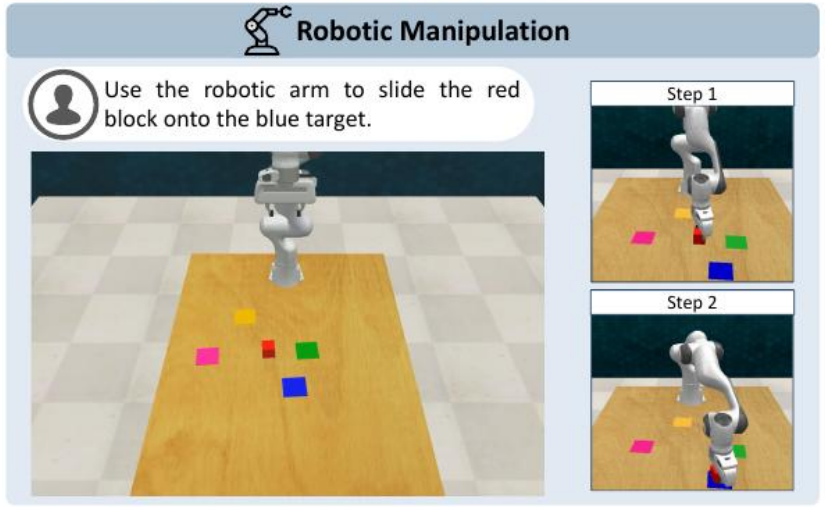
世界模型负责未来帧生成，之后将结果交给**修正策略（qwen）**来根据目标图像、当前观测、候选动作和预测画面选择方案

03 不同任务类型和动作候选方案生成策略









主动识别 AR：2个动作候选方案，动作预测长度为4

图像目标导航 ImageNav：3个动作候选方案，动作预测长度为5

主动具身问答 A-EQA：3个动作候选方案，动作预测长度为14

机器人操作：VLM 输出离散化的末端执行器动作，5个动作候选方案，动作预测长度为5

机器人操作：3D Diffuser Actor 采样连续动作轨迹，5个动作候选方案，动作预测长度为50

针对动作进行的专项训练

一、视频与动作对齐

1、室内导航 Habitat：收集每一步的全景RGB

2、机械臂操作 RLBench：收集每一步的前视RGB

动作必须和它造成的画面变化准确对应

二、动作的具体输入

采取micro_cond方案，将动作编码初始第一步用停止动作（ID：4）占位

第一帧：4、0、0、0、、、

第二帧：4、2、0、0、、、

第三帧：4、2、1、0、、、

第四帧：4、2、1、3、、、

每一个帧对应的动作条件均包含先前所有动作信息

三、一次训练迭代到底做什么？

1、将整段视频压缩为VAE潜变量Z

2、对其加噪声，制成Z_a

3、将初始画面的图像特征、整段动作条件和Z_a和VAE 条件潜变量的拼接送入U-net

4、对去噪后的输出Zr与Z比较并进行反向传播

Model Details					AR		ImageNav		
Model Type	Method	Control Type	Input Type	#Param.	SR ↑	Mean Traj. ↓	SR ↑	Mean Traj. ↓	SPL ↑
Base Policy	Heuristic (w/o WM)	–	RGB	–	39.02	8.81	2.08	59.6	0.63
+ Video Gen. Post-Train	SVD†	Action	RGB; Pano	1.5B	60.62	5.17	20.83	58.5	11.86
	WAN2.1†	Action	RGB; Pano	14B	62.98	4.71	22.92	58.7	11.63
Base Policy	VLM (w/o WM)	–	RGB	72B	50.27	6.24	35.42	47.5	25.88
+ Image Gen.	PathDreamer	Viewpoint	RGB-D; Pano	0.69B	56.99	5.28	36.80	47.3	26.85
+ Image Gen.	SE3DS	Viewpoint	RGB-D; Pano	1.1B	57.53	5.29	36.11	47.0	26.91
+ Video Gen.	NWM	Trajectory	RGB	1B	57.35	5.68	40.28	47.1	27.83
+ Video Gen. Zero-Shot	SVD	Image	RGB	1.5B	57.71	5.29	40.28	46.4	28.59
	LTX-Video	Text	RGB	2B	56.08	5.37	36.81	47.5	25.85
	Hunyuan	Text	RGB	13B	57.71	5.21	36.11	46.8	26.89
	Wan2.1	Text	RGB	14B	58.26	5.24	38.19	48.2	25.92
	Wan2.2	Text	RGB	5B	55.35	5.73	38.88	46.5	28.87
	Cosmos-P2	Text	RGB	2B	55.35	5.71	36.81	47.6	25.89
	Cosmos-P2.5	Text	RGB	2B	58.26	5.12	36.81	47.7	26.57
	Wan2.2	Text	RGB	A14B	**59.53**	**4.91**	**43.05**	**45.8**	**31.46**
	Runway Gen4 (proprietary)	Text	RGB	–	64.79	4.06	-	-	-
+ Video Gen. Post-Train	SVD†	Action	RGB; Pano	1.5B	60.98	5.02	43.05	46.0	30.96
	LTX-Video†	Action	RGB; Pano	2B	57.53	5.49	38.89	47.4	27.47
	WAN2.1†	Action	RGB; Pano	14B	**62.61**	4.73	45.14	45.8	32.10
	Cosmos-P2†	Action	RGB; Pano	2B	60.25	5.08	41.67	45.5	30.29
	Wan2.2†	Action	RGB; Pano	5B	56.26	5.15	38.89	46.7	28.24
	Wan2.2†	Action	RGB; Pano	A14B	62.43	**4.67**	**46.53**	**44.6**	**34.61**

在主动识别和图像导航上均有提升

主动具身问答 A-EQA

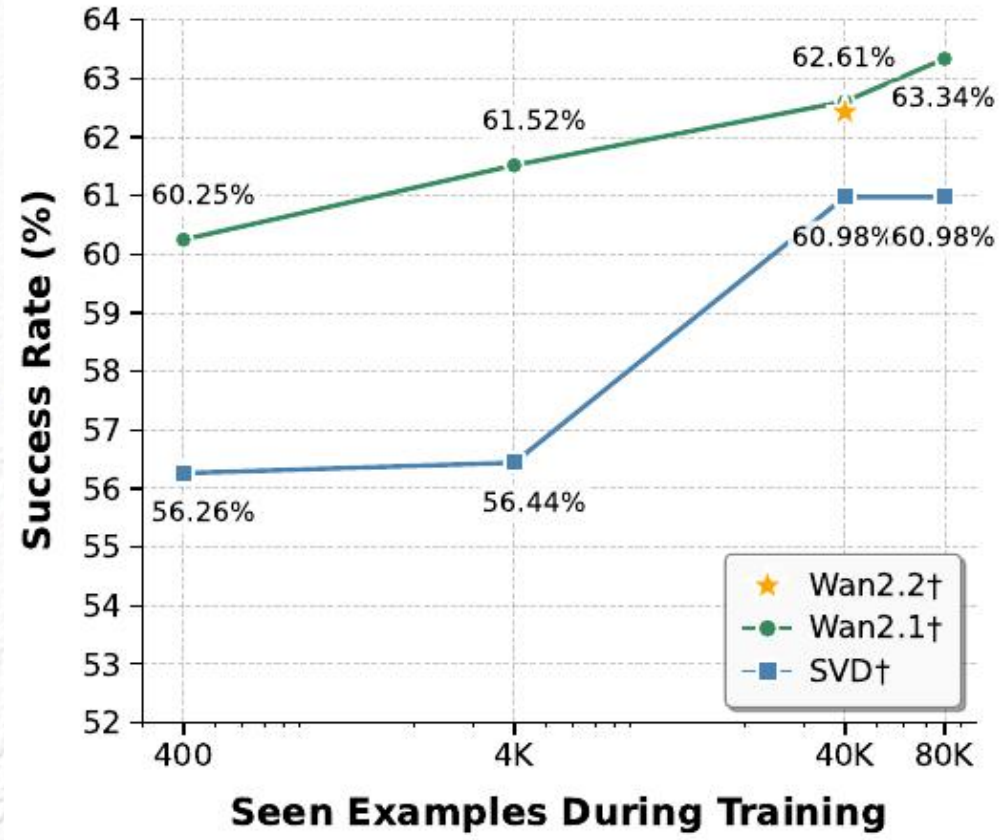
Model Details		A-EQA Performance		
Model Type	Method	Ans. Score ↑	Mean Traj. ↓	SPL ↑
Base Policy	VLM (w/o WM)	45.7	20.4	29.6
+ Image Gen.	PathDreamer	46.0	20.4	29.3
+ Image Gen.	SE3DS	45.8	20.3	29.4
+ Video Gen.	NWM	47.1	20.5	30.1
+ Video Gen.	Wan2.1	45.7	**20.1**	28.8
	Wan2.2 (5B)	46.3	20.3	31.4
	LTX-Video	46.6	20.8	29.5
	Cosmos-P2	46.6	21.0	31.3
	Hunyuan	46.8	20.4	29.9
	SVD	46.9	20.4	29.7
	Wan2.2 (A14B)	**47.2**	20.7	**31.9**
+ Video Gen. Post-Train	SVD†	46.4	21.1	30.1
	Cosmos-P2†	46.5	20.6	30.1
	Wan2.2† (5B)	47.5	20.8	30.7
	Wan2.1†	48.2	20.7	31.6
	LTX-Video†	**48.6**	20.7	31.8
	Wan2.2† (A14B)	48.4	**20.2**	**31.9**

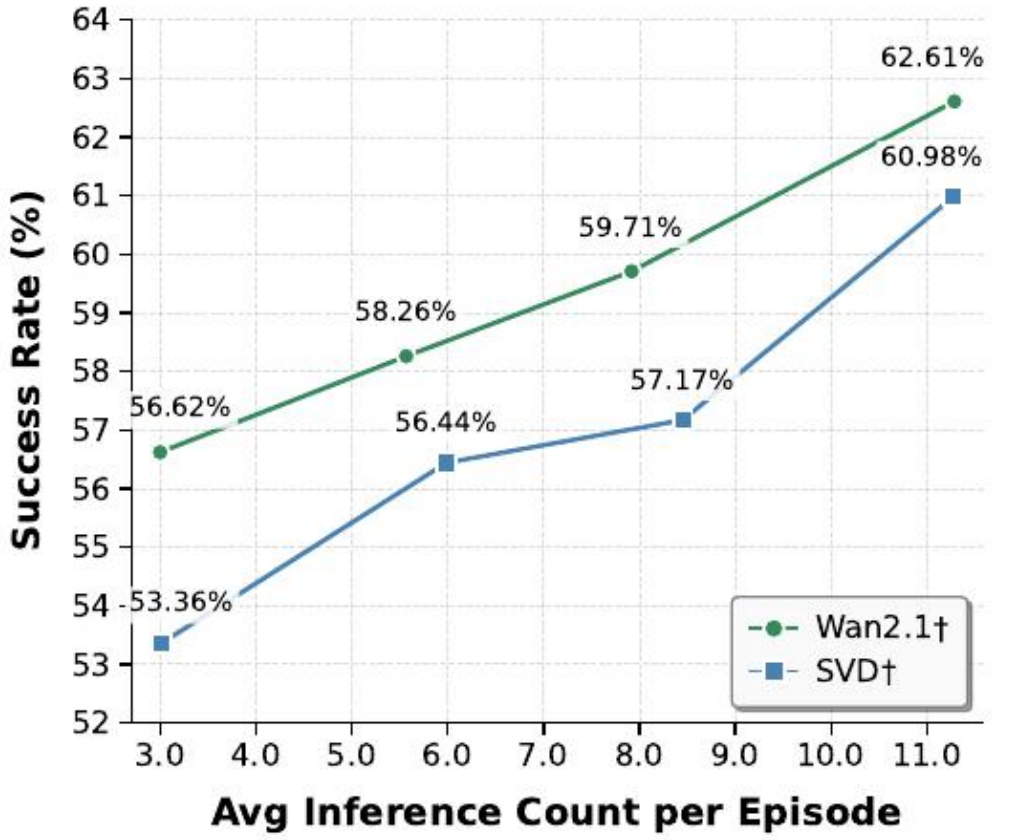
在具身问答上有稳定提升但不明显

机器人操作

Model Details		Manipulation Performance	
Model Type	Method	SR ↑	Mean Traj. ↓
Base Policy	VLM (w/o WM)	44.5	2.52
+ Video Gen.	SVD	44.0	2.47
	LTX-Video	44.5	2.46
	Hunyuan	44.5	2.44
	Wan2.1	44.0	2.51
	Cosmos-P2	44.0	2.50
+ Video Gen. Post-Train	SVD†	46.5	2.38
	Cosmos-P2†	45.0	2.40
Base Policy	3D-DP (w/o WM)	24.0	5.21
+ Video Gen. Post-Train	SVD†	44.7	4.41
	Cosmos-P2†	38.0	4.79

操作收益有限，对于物理效果的预测仍然困难



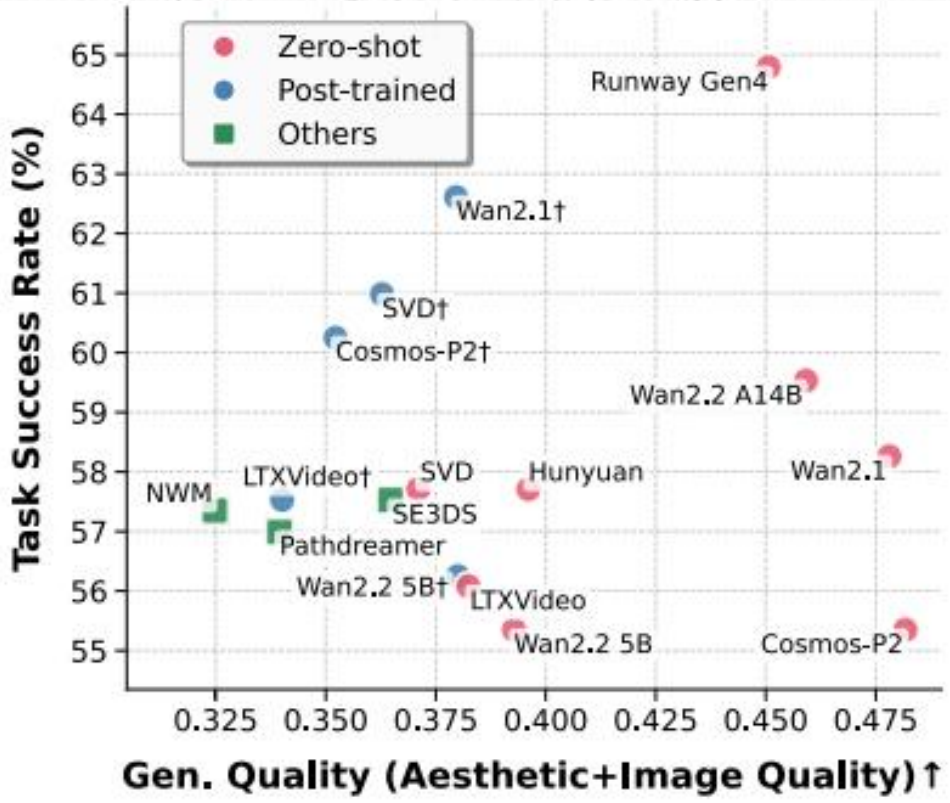


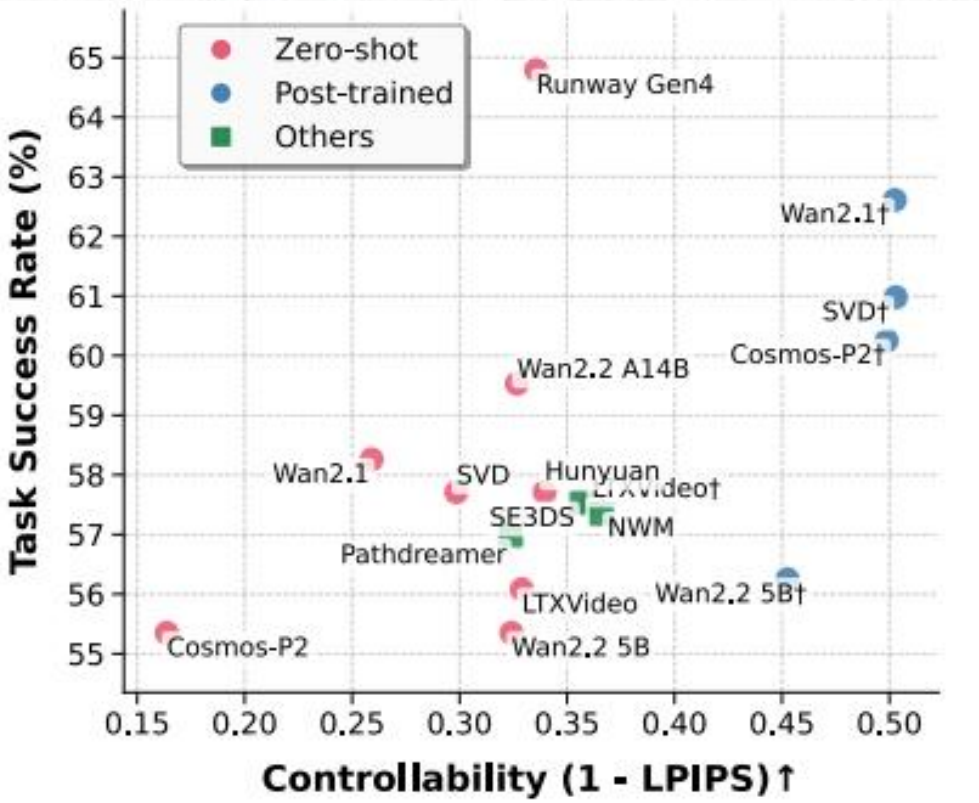
一、后训练越多成绩越好

二、不同模型利用更多数据的能力不同

三、更换更新的基座，不一定比充分后训练更有效

调用世界模型次数越多成绩越好，目前仅在AR任务上有体现。





画质好不代表成绩好

可控性（1-LPIPS）越高
成绩越好

Task	Model	Front View		Panorama	
		SR ↑	Mean Traj. ↓	SR ↑	Mean Traj. ↓
AR	SVD†	57.89	5.04	60.98	5.02
	Wan2.1†	62.25	4.82	62.61	4.73
	Wan2.2† (5B)	57.16	5.08	56.26	5.15
	Cosmos-P2†	58.98	4.94	60.25	5.08
ImageNav	SVD†	38.19	47.0	43.05	46.0
	Wan2.1†	48.61	43.8	45.14	45.8
	Wan2.2† (5B)	40.97	45.8	38.89	46.7
	Cosmos-P2†	40.97	47.0	41.67	45.5

$\pi_{proposal}$	WM Type	$\pi_{revision}$	SR ↑	Mean Traj. ↓	SPL ↑
VLM	None	None	35.42	47.5	25.88
VLM	SVD†	VLM	43.05	46.0	30.96
VLM	Wan2.1†	VLM	45.14	45.8	32.10
VLM	SVD†	LPIPS	47.92	41.3	39.82
VLM	Wan2.1†	LPIPS	48.61	39.8	42.48

WM Aug.	Post-Train Env.	AR		ImageNav	
		SR ↑	Mean Traj. ↓	SR ↑	SPL ↑
w/o WM	None	50.27	6.24	35.42	25.88
+SVD†	HSSD	58.98	5.24	38.89	27.60
+Wan2.1†	HSSD	62.98	4.78	42.36	31.18
+SVD†	HM3D (train)	60.98	5.02	43.05	30.96
+Wan2.1†	HM3D (train)	62.61	4.73	45.14	32.10